

FACULTAD DE INGENIERÍA, DISEÑO Y CIENCIAS APLICADAS
Escuela de Tecnología, Diseño e Innovación Departamento De Computación y
Sistemas Inteligentes.

Información de la asignatura

Programa	Maestría en Inteligencia Artificial Aplicada
Periodo Académico	2025-1
Grupo	
NRC	
Nombre de la asignatura	Aprendizaje Automático I
Código de la asignatura	
Intensidad horaria¹	36 horas
Intensidad semanal¹	
Créditos¹	3
Docente(s)	Milton Orlando Sarria Paja

Introducción o presentación general del curso

En este curso se estudian los conceptos del modelamiento estadístico, desde el enfoque lineal de las variables explicativas. El curso brinda las herramientas necesarias para estimar modelos lineales que permitan explicar el comportamiento de variables cuantitativas y binarias en término de otras, así como variaciones de los mismos. Se estudiarán técnicas para seleccionar el mejor modelo en términos de minimización de error y cantidad óptima de variables. Así mismo, se discuten pruebas para validar el cumplimiento de los supuestos del modelo de regresión múltiple, así como las opciones para solucionar la existencia de una violación de los supuestos teóricos o sobre los datos. El curso emplea el lenguaje de programación Python, además, se hace énfasis en la interpretación de los resultados para tomar decisiones bajo incertidumbre.

Formación en competencias**C: Competencia / RA: Resultado de Aprendizaje**

C2. Ética y Responsabilidad Social. Actuar en la práctica profesional teniendo en cuenta la responsabilidad ética y social.

RA2.1. Decidir de manera ética previo al desarrollo de sus acciones, considerando los impactos que estas puedan generar.

C3. Solución de Problemas. Solucionar problemas complejos usando pensamiento sistémico e información relevante.

¹ La intensidad horaria, intensidad semanal y créditos, deben estar alineados con la “Política de definición de créditos académicos de la Universidad Icesi” – Resolución N°. 80 de Junta Directiva del 22 de septiembre de 2019.

RA3.1 Examinar problemas complejos aplicando el pensamiento sistémico y plantear soluciones basadas en conocimiento e información relevante.

C.4: Competencia profesional (Aprendizaje automático): Aplicar distintos métodos para construir modelos de aprendizaje automático a partir de la identificación de patrones, cuyos resultados permitan apoyar la toma de decisiones en una organización.

R.4.1 - R.6.1: Seleccionar el modelo de Ciencia de Datos más adecuado para un conjunto de datos específico, justificando la elección basada en características del problema y las propiedades de los datos.

RA.4.2: Desarrollar un modelo de Aprendizaje Automático adecuado para resolver problema específico con técnicas apropiadas y a partir de un conjunto de datos dado.

R.4.3: Evaluar la efectividad de los modelos de Ciencia de Datos utilizando métricas específicas y adecuadas, interpretando los resultados para apoyar la toma de decisiones informadas en una organización.

Tabla 1: competencias y Nivel de formación

Competencia	Nivel
C2. Ética y responsabilidad social	Introduce
C3. Solución de problemas	Introduce
C4. Competencia profesional: Aprendizaje automático	Introduce

Objetivo general de aprendizaje (meta de aprendizaje)

Al finalizar el curso, el estudiante estará en capacidad de aplicar modelos de regresión lineal y logística para variables cuantitativas y binarias, evaluando su ajuste y comunicando los resultados para la toma de decisiones informadas.

Resultados de aprendizajes de la asignatura (Objetivos terminales)

RA1: Proponer modelos de regresión lineal a conjuntos de datos, con el fin de interpretar el significado de las estimaciones resultantes y valorar el ajuste del modelo, a través de la aplicación de inferencia estadística.

RA2: Diagnosticar problemas de multicolinealidad, presencia de observaciones atípicas y selección de variable, con el fin de proponer soluciones como técnicas de regularización y robustecimiento.

RA3: Proponer modelos de regresión logística, y a su vez versiones regularizadas del mismo, en escenarios de clasificación binaria de datos, con el fin de interpretar el significado de las estimaciones resultantes.

RA4: Desarrollar modelos de regresión y clasificación empleando el algoritmo KNN

RA5: Comunicar de manera escrita los resultados obtenidos de un modelo lineal generalizado aplicado a un conjunto de datos.

Resultado de aprendizaje del curso o asignatura (Objetivos terminales)	Competencia en formación	Resultado de aprendizaje de la competencia de egreso al que se contribuye
RA1	C3	RA3.1
RA2	C3, C4, C6	RA3.1, R.4.1 - R.6.1
RA3	C3, C4, C6	RA3.1, R.4.1 - R.6.1
RA4	C3, C4, C6	RA3.1, R.4.1 - R.4.2 - R.4.3
RA5	C2, C4, C6	RA2.1. , R.4.1 - R.4.2 - R.4.3

Unidades de aprendizaje

Unidad de aprendizaje #1: Modelo de Regresión Lineal

Esta unidad introduce el concepto de estructuras de dependencia y correlación entre variables, para luego introducir el modelo lineal, los supuestos teóricos subyacentes y algunas variantes del mismo.

Objetivos específicos de aprendizaje

- Ajustar y estimar un modelo de regresión e interpretar el significado de las estimaciones resultantes.
- Valorar la bondad y ajuste del modelo de regresión, a través de la aplicación de inferencia estadística.
- Proponer modelos de regresión de acuerdo a la naturaleza de las variables explicativas, ya sea a partir de aplicación de transformaciones o la adición de variables categóricas.
- Aplicar las metodologías de regresión lineal en software estadístico.

Unidad de aprendizaje #2: Modelo de Regresión Logística

Esta unidad introduce el concepto de clasificación, en que consiste un problema de clasificación binaria, la diferencia entre un modelo de regresión para variable cuantitativa y binaria. Introduce el modelo logístico de regresión.

Objetivos específicos de aprendizaje

- Identificar en un conjunto de datos cuando y como se presentan escenarios de clasificación binaria de registros.
- Ajustar y estimar un modelo de regresión logístico e interpretar el significado de las estimaciones resultantes.
- Comprender las medidas de desempeño en términos de clasificación.

- Proponer modelos de regularización, de acuerdo a la estructura y condición de los datos y, a su vez, medir la potencia de clasificación de cada uno.

Unidad de aprendizaje #3: Regularización

La regularización es un concepto clave en machine learning utilizado para prevenir el sobreajuste (overfitting) y mejorar la generalización de los modelos. En esta unidad, exploraremos los aspectos teóricos y conceptuales de la regularización, y proporcionaremos ejemplos prácticos para la estimación del modelo de regresión lineal y regresión logística (Ridge, LASSO, Elastic-Net).

Objetivos específicos de aprendizaje

- Identificar en un conjunto de datos cuando y como se presentan los problemas de multicolinealidad y que métricas sirven para ello.
- Identificar los escenarios en que un modelo de regresión lineal requiere selección de variables y/o reducción de dimensión.

Unidad de aprendizaje #4: Métricas de Evaluación

Esta unidad aborda las principales métricas de evaluación de modelos de aprendizaje automático supervisado, tanto para problemas de regresión como de clasificación. Se exploran las propiedades, limitaciones y casos de uso de cada métrica, y se introduce la importancia de la validación cruzada como protocolo para medir la efectividad de los modelos.

Objetivos específicos de aprendizaje

- Identificar las métricas más relevantes para evaluar modelos de clasificación y regresión según el tipo de problema y datos.
- Calcular e interpretar métricas como precisión, recall, F1-score, ROC-AUC, RMSE, y MAE.
- Diferenciar entre métricas basadas en errores y métricas basadas en probabilidades o decisiones binarias.
- Comprender la importancia de los protocolos de validación, como el holdout y la validación cruzada, en la evaluación del desempeño de un modelo.

Unidad de aprendizaje #5: K-Nearest Neighbors (KNN)

Esta unidad introduce el modelo de aprendizaje basado en instancias KNN, analizando su funcionamiento, ventajas y desventajas. Además, se aborda su desempeño en problemas de clasificación y regresión. Se complementa con una discusión sobre el impacto de la normalización de datos y la selección del valor de k .

Objetivos específicos de aprendizaje

- Explicar el funcionamiento del algoritmo KNN para clasificación y regresión.
- Evaluar el impacto de la distancia y la normalización de variables en los resultados de KNN.
- Aplicar KNN en problemas prácticos y comparar su desempeño con otros modelos básicos

Metodologías de aprendizajes

La metodología del curso se basa en el modelo de aprendizaje activo. Bajo este modelo el estudiante debe preparar previamente el material que se verá en cada clase, de modo que el estudiante tenga en realidad una participación activa en la construcción de su conocimiento. Con este estudio previo el estudiante preparará preguntas sobre los temas que se verán en clase. El profesor, por su parte, administrará la experiencia de aprendizaje del estudiante, de manera tal que motive, guíe y complemente la información adquirida por el estudiante en su trabajo previo a la clase. Se busca de esta forma maximizar la experiencia de aprendizaje del estudiante.

Antes de clase el estudiante debe:

- Estudiar el material asignado en la programación del curso.
- Elaborar preguntas sobre el tema estudiado con el fin de ser discutidas con los compañeros de clase.

Durante la clase el estudiante debe:

- Plantear preguntas que hayan surgido antes y durante el estudio previo del tema de clase.
- Participar activamente en las actividades que proponga el profesor.
- Resolver los ejercicios que asigne el profesor durante la clase.

Después de clase el estudiante debe:

- Revisar el material visto en clase, con el fin de asegurarse de haber comprendido el tema y tener resueltas las dudas que hubieran surgido previamente.
- Realizar los ejercicios o tareas asignadas por el profesor.

Evaluación de aprendizajes

La evaluación del curso se desarrollará por unidades, de acuerdo al contenido del curso, y se realizará en equipos de entre tres y cuatro estudiantes. Cada evaluación contemplará la realización de ejercicios prácticos, asociados a los temas desarrollados en clase y ejercicios de tipo investigativo, en donde los estudiantes deberán buscar y leer artículos científicos sobre metodologías, temas, recursos, avances de alguno de los subtemas de clase e implementarlos.

La evaluación de la Unidad 1 se asignará durante las clases 4 – 5 y deberá ser entregada en los siguientes 10 días hábiles. Las unidades 2 y 3 serán evaluadas en conjunto al finalizar el curso, se asignará en la clase 9 y deberá ser entregada en los siguientes 10 días hábiles.

Mecanismo o actividad evaluativa	Porcentaje de la nota final	Relación con resultados de aprendizaje del curso	Relación con el resultado de aprendizaje de la competencia de egreso
Examen 1	30%	RA1 – RA2 - RA5	RA3.1, R.4.1 - R.6.1, RA2.1. , R.4.1 - R.6.1, R.4.2 - R.6.2
Examen 2	40%	RA2 - RA3 – RA5	RA3.1, R.4.1 - R.6.1, RA2.1. , R.4.1 - R.6.1, R.4.2 - R.6.2
Examen 3	30%	RA3 – RA4 – RA5	RA2.1, RA3.1, R.4.1 - R.6.1, R.4.2 - R.6.2

Medios Educativos.

Software

Python, Jupyter, IDE Spyder, Github, Data Pipelines, Xournal++.

Recursos físicos

Aula de Clase, Sala virtual (Zoom, meet, etc.), Computador central, Micrófono, Video Beam, Tableta Digitalizadora Wacom.

Bibliografía sugerida

Aylin, A. (2010), "Multicollinearity," WIREs Computational Statistics, 2, 370 - 374.

Baíllo Moreno, A. and Grané Chavez, A. (2008), 100 Ejercicios Resueltos de Estadística Multivariante (Implementados en Matlab), Delta Publicaciones.

Hastie, T., Tibshirani R. and Friedman, J. (2009), The Elements of Statistical Learning, Springer Texts in Statistics, Springer.

Hastie, T., Tibshirani R. and Wainwright, M. (2015), Statistical Learning with Sparsity the Lasso and Generalizations, Monographs on Statistics and Applied Probability 143, CRC Press.

Hesterberg, T. (2011), "Bootstrap," WIREs Computational Statistics, 3, 497 - 526.

James, G., Witten, D., Hastie, T. and Tibshirani R. (2013), An Introduction to Statistical Learning with Applications in R, Springer Texts in Statistics, Springer.

Jiménez Moscoso, J. A. (2012), Álgebra Matricial con Aplicaciones en Estadística, Facultad de Ciencias, Universidad Nacional de Colombia.

Myers, R., Montgomery, D., Vining, G. and Robinson, T. (2012), The Generalized Linear Model with Applications in Engineering and the Sciences, John Wiley & Sons.

Peña, D. (2002), Análisis de Datos Multivariantes, McGraw-Hill.

Rencher, A. C. (2002), Methods of Multivariate Analysis, John Wiley & Sons.

Stigler, S. M. (1981), "Gauss and the Invention of Least Squares," The Annals of Statistics, 9, 465 - 474.