



Comenzado el

jueves, 11 de septiembre de 2025, 20:30

Estado

Finalizado

Finalizado en

jueves, 11 de septiembre de 2025, 22:00

Tiempo empleado

1 hora 29 minutos

Puntos

50,00/59,00

Calificación

4,24 de 5,00 (84,75%)

Pregunta 1

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Tienes un modelo de regresión lineal simple para predecir precios de casas. Observas que el RMSE en los datos de entrenamiento es bajo, pero en los de prueba es mucho mayor. _____

¿Qué estrategia es más adecuada para mejorar el desempeño en los datos de prueba?

- ☐ a. Eliminar outliers únicamente del conjunto de prueba.
- ☐ b. Disminuir la cantidad de datos de entrenamiento.
- ☒ c. Aplicar regularización (Ridge o Lasso). ✓
- ☐ d. Ninguna de las opciones es correcta
- ☐ e. Aumentar la complejidad del modelo agregando más términos polinomiales.

Respuesta correcta

El problema es **overfitting**. Regularización penaliza la magnitud de los coeficientes, ayudando a reducir el sobreajuste.

Más complejidad aumentaría el overfitting.

Menos datos de entrenamiento empeora generalización.

Eliminar outliers sólo del conjunto de prueba viola la validación honesta.

La respuesta correcta es: **Aplicar regularización (Ridge o Lasso).**

Pregunta 2

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Caso:

Un especialista en IA entrena un modelo de regresión para predecir el precio de viviendas. Usa validación cruzada ($k=10$) y obtiene resultados muy variables: los R^2 van desde 0.45 hasta 0.89 entre folds. El dataset tiene muchos valores atípicos. _____

¿Cuál sería una **mejora más adecuada** para estabilizar los resultados?

- ☒ a. Remover outliers antes del entrenamiento ✓
- ☐ b. Usar una métrica diferente como MAE
- ☐ c. Escoger el fold con mayor R^2 para el modelo final
- ☐ d. Ninguna de las opciones es correcta
- ☐ e. Aumentar el número de folds a 20

Respuesta correcta

La alta variabilidad entre folds sugiere sensibilidad a valores extremos. Remover o tratar outliers puede estabilizar el aprendizaje. Cambiar la métrica no soluciona el problema raíz. Aumentar los folds puede empeorar la varianza. Elegir el mejor fold introduce sesgo.

La respuesta correcta es: **Remover outliers antes del entrenamiento**

Pregunta 3

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Caso:

Un equipo de análisis propone usar un modelo de regresión lineal para predecir si un cliente comprará un producto (1: compra, 0: no compra). Argumentan que el valor predicho puede interpretarse como una probabilidad. _____

¿Cuál es el error conceptual en esta propuesta?

- ☐ a. La regresión lineal siempre tiene menor precisión que la logística
- ☐ b. La regresión lineal no puede procesar variables categóricas
- ☐ c. La regresión lineal no puede clasificar, solo predecir
- ☒ d. La regresión lineal no garantiza salidas en el rango $[0, 1]$ ✓

Respuesta correcta

La regresión lineal no está diseñada para clasificación binaria, y puede generar valores predichos fuera del rango $[0, 1]$, lo cual no es coherente como probabilidad. La regresión logística, en cambio, transforma la salida con una función sigmoide. Las otras opciones contienen afirmaciones incorrectas o incompletas.

La respuesta correcta es: **La regresión lineal no garantiza salidas en el rango $[0, 1]$**

Pregunta 4

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Tras entrenar un modelo para diagnosticar cáncer (clase positiva: cáncer), se obtiene una curva ROC con $AUC = 0.85$. El área bajo la curva (AUC) en el conjunto de prueba es significativamente menor que en entrenamiento. _____

Podemos afirmar que:

- ☒ a. Hay overfitting; se recomienda regularizar el modelo o reducir características. ✓
- ☐ b. El AUC bajo en el el conjunto de prueba se debe solo al tamaño del dataset. Se recomienda hacer una partición con porcentajes diferentes.
- ☐ c. El modelo tiene alto bias (subajuste). Se recomienda aumentar la complejidad del modelo. Un modelo más complejo tiene menos posibilidad de sufrir sobreajuste.
- ☐ d. La curva ROC no es útil para problemas médicos. Se recomienda usar otras métricas.

Respuesta correcta

Hay overfitting; regularizar el modelo o reducir características -> es correcto: la discrepancia AUC (train >> test) sugiere overfitting; técnicas como L2 o feature selection pueden ayudar.

Las otras opciones son incorrectas porque: alto bias reduciría AUC en ambos conjuntos. El tamaño afecta la varianza de la métrica, no su valor esperado. La curva ROC es estándar en medicina para evaluar trade-offs sensibilidad/especificidad.

La respuesta correcta es:

Hay overfitting; se recomienda regularizar el modelo o reducir características.

Pregunta 5

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Caso:

Un analista de marketing ajusta una regresión lineal para modelar el gasto mensual de clientes a partir del ingreso. Al graficar los residuos vs. valores predichos, observa una forma de abanico: los residuos son pequeños para predicciones bajas y se dispersan progresivamente conforme aumenta el ingreso.

¿Qué supuesto está siendo violado?

- ☐ a. Linealidad
- ☒ b. Homocedasticidad ✓
- ☐ c. Normalidad de los residuos
- ☐ d. Ninguna de las opciones es correcta
- ☐ e. Independencia de errores

Respuesta correcta

La homocedasticidad implica que la varianza del error debe ser constante a lo largo de los valores predichos. Un patrón en forma de abanico sugiere **heterocedasticidad**, lo que invalida algunos intervalos de confianza e inferencias. La normalidad y linealidad no se diagnostican con este tipo de gráfico.

La respuesta correcta es: **Homocedasticidad**

Pregunta 6

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Caso:

Una empresa modela el tiempo de entrega de paquetes en función de la distancia entre origen y destino. Al graficar los residuos versus el predictor, el analista observa un patrón curvilíneo en forma de U invertida. _____

¿Qué sugiere este patrón respecto al modelo ajustado?

- ☐ a. Ninguna de las opciones es correcta
- ☐ b. El modelo tiene varianza constante
- ☐ c. El modelo está sobreajustado
- ☐ d. El modelo viola la independencia de errores
- ☒ e. El modelo no captura adecuadamente la relación no lineal ✓

Respuesta correcta

Un patrón sistemático como una curva en los residuos indica que la suposición de **linealidad** entre predictores y respuesta no se cumple. Esto puede remediarse con transformaciones o modelos no lineales. Las otras opciones son incorrectas o irrelevantes en este contexto.

La respuesta correcta es: **El modelo no captura adecuadamente la relación no lineal**

Pregunta 7

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Caso:

Un hospital desarrolla un modelo de regresión logística para predecir si un paciente será readmitido (1) o no (0) después del alta. Uno de los predictores es el número de días de hospitalización (`dias_hosp`). El modelo entrega el siguiente coeficiente para `dias_hosp` :

$$\beta = 0.35 \text{ (} p < 0.01 \text{)}$$

¿Cuál de las siguientes afirmaciones es la interpretación más adecuada de este coeficiente?

- ☐ a. Por cada día adicional de hospitalización, la probabilidad de readmisión aumenta en 35%
- ☐ b. Ninguna de las opciones es correcta
- ☐ c. El coeficiente indica que la readmisión es más probable que no ser readmitido
- ☒ d. Por cada día adicional de hospitalización, la razón de probabilidades (odds) de readmisión se multiplica por $\exp(0.35)$ ✓
- ☐ e. El aumento de un día en hospitalización no afecta significativamente la readmisión

Respuesta correcta

En regresión logística, los coeficientes no se interpretan directamente como cambios en probabilidad, sino como **cambios en los log-odds**. $\exp(\beta)$ representa el factor por el cual se multiplican los **odds** al aumentar una unidad del predictor. En este caso, $\exp(0.35) \approx 1.42$, lo que significa un aumento del 42% en los **odds**, no en la probabilidad directamente.

La respuesta correcta es:

Por cada día adicional de hospitalización, la razón de probabilidades (odds) de readmisión se multiplica por $\exp(0.35)$

Pregunta 8

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Un equipo construye un modelo de clasificación para detectar correos spam usando un dataset fuertemente desbalanceado (5% spam, 95% no spam).

¿Cuál de las siguientes métricas es la mejor para evaluar el desempeño del modelo?

- ☐ a. Ninguna de las opciones es correcta
- ☐ b. Mean Absolute Error.
- ☒ c. Recall para la clase spam. ✓
- ☐ d. Accuracy.
- ☐ e. R^2 Score.

Respuesta correcta

En problemas desbalanceados, el **recall** en la clase minoritaria (spam) es crítico para capturar la mayor cantidad de correos no deseados.

Accuracy será engañosamente alta.

R^2 es para regresión, no clasificación.

MAE también es para regresión.

La respuesta correcta es: **Recall para la clase spam.**

Pregunta 9

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

En un modelo de regresión lineal para predecir el precio de viviendas, el error (RMSE) es alto y los residuos muestran un patrón no lineal (en forma de U)._____

¿Qué acción es más adecuada para mejorar el modelo?

- ☐ a. Aumentar la regularización L2 (Ridge).
- ☐ b. Aplicar log-transform a la variable objetivo.
- ☐ c. Ninguna de las opciones es correcta
- ☒ d. Cambiar a un modelo de regresión polinómica. ✓
- ☐ e. Eliminar outliers del dataset.

Respuesta correcta

Los residuos con patrón no lineal sugieren que la relación entre variables no es lineal. Un modelo polinómico capturaría mejor esta relación.

Aplicar log-transform a la variable objetivo: Útil si la distribución de la variable objetivo es sesgada, pero no corrige no-linealidad.

Ridge reduce sobreajuste pero no mejora sesgo por no-linealidad.

Outliers no explican el patrón sistemático en residuos.

La respuesta correcta es: **Cambiar a un modelo de regresión polinómica.**

Pregunta 10

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Al aplicar KNN en un dataset numérico observas muy mal desempeño. _____

¿Qué preprocesamiento podría mejorar los resultados?

- ☐ a. Eliminar instancias atípicas manualmente.
- ☐ b. Aplicar PCA antes del KNN.
- ☐ c. Ninguna de las opciones es correcta
- ☒ d. Normalización o estandarización de características. ✓
- ☐ e. One-hot encoding.

Respuesta correcta

KNN depende de distancias -> **normalizar** garantiza que ninguna variable domine.

One-hot es para variables categóricas.

PCA puede ayudar pero primero hay que normalizar antes, típicamente estandarizar.

No siempre es necesario eliminar outliers.

La respuesta correcta es: **Normalización o estandarización de características.**

Pregunta 11

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Entrenas KNN en un dataset con 3000 variables. El accuracy en el conjunto de prueba es bajo pese a un buen desempeño en el conjunto de entrenamiento. _____

¿Qué fenómeno es el principal responsable?

- ☐ a. Uso de un k demasiado grande.
- ☐ b. Ninguna de las opciones es correcta
- ☒ c. Efecto de la "maldición de la dimensionalidad". ✓
- ☐ d. Sobreajuste por alta varianza.
- ☐ e. Mal ajuste de la métrica de distancia.

Respuesta correcta

En alta dimensión, **todas las distancias** tienden a ser similares, volviendo inefectivas las comparaciones de vecinos.

Aunque puede haber sobreajuste, el problema raíz es la dimensionalidad.

Aunque métricas distintas ayudan, la dimensionalidad extrema lo domina.

k grande suaviza, pero no resuelve dimensionalidad.

La respuesta correcta es: **Efecto de la "maldición de la dimensionalidad"**.

Pregunta 12

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Al entrenar un clasificador binario, la curva ROC muestra $AUC = 0.65$. _____

¿Qué interpretación es correcta?

- ☒ a. El modelo es mejor que aleatorio pero con margen de mejora. ✓
- ☐ b. El modelo no es mejor que adivinar al azar ($AUC = 0.5$).
- ☐ c. Ninguna de las opciones es correcta
- ☐ d. La métrica AUC no aplica para clasificación binaria.
- ☐ e. El modelo tiene alta precisión pero bajo recall.

Respuesta correcta

$AUC > 0.5$ indica que el modelo supera el azar, pero 0.65 es bajo (ideal: $AUC \approx 1$).

La curva ROC no mide precisión/recall directamente.

$AUC = 0.5$ sería equivalente a aleatorio.

AUC es estándar para clasificación binaria.

La respuesta correcta es: **El modelo es mejor que aleatorio pero con margen de mejora.**

Pregunta 13

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Al aplicar KNN a un dataset con características en escalas diferentes (ej.: edad [0-100] vs. ingreso [0 – 1M])._____

¿Qué paso es crítico antes de entrenar?

- ☐ a. Ninguna de las opciones es correcta
- ☐ b. Aplicar one-hot encoding.
- ☒ c. Normalizar las características (ej.: StandardScaler). ✓
- ☐ d. Convertir todas las variables a categóricas.
- ☐ e. Seleccionar k óptimo con GridSearchCV.

Respuesta correcta

Normalizar las características: KNN usa distancias (ej.: euclidiana), por lo que escalas diferentes distorsionan resultados.

GridSearchCV es útil pero secundario a normalización.

KNN requiere variables numéricas.

One-hot encoding no resuelve el problema de escala.

La respuesta correcta es: **Normalizar las características (ej.: StandardScaler).**

Pregunta 14

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Una empresa de seguridad bancaria ha entrenado un modelo de clasificación para detectar transacciones fraudulentas. El dataset contiene 1% de fraudes y 99% de transacciones legítimas. El equipo muestra con orgullo una precisión del 99%._____

¿Cuál métrica sería más adecuada para evaluar el desempeño real del modelo en este caso?

- ☒ a. AUC-ROC ✓
- ☐ b. Ninguna de las opciones es correcta
- ☐ c. R^2
- ☐ d. MAE (Mean Absolute Error)
- ☐ e. Precisión (Accuracy)

Respuesta correcta

Dado el gran desbalance de clases, la **precisión (accuracy)** puede ser engañosa: un modelo que siempre predice "no fraude" tendría 99% de precisión pero sería inútil.

El **AUC-ROC** mide la capacidad del modelo para distinguir entre clases y es más informativo en escenarios desbalanceados.

Las otras opciones se usan para regresión, por lo tanto no aplican aquí.

La respuesta correcta es: **AUC-ROC**

Pregunta 15

[Marcar pregunta](#)**Correcta**

Se puntúa 1,00 sobre 1,00

Caso:

Un modelo predictivo de enfermedad cardíaca fue evaluado en 1000 pacientes. La matriz de confusión fue:

	Predicción Positiva	Predicción Negativa
Real Positivo	80	20
Real Negativo	150	750

¿Qué métrica se ve más afectada de forma negativa en este modelo?

- ☒ a. Precisión (Precision) ✓
- ☐ b. Especificidad
- ☐ c. Sensibilidad (Recall)
- ☐ d. Accuracy

Respuesta correcta

La precisión se ve afectada por la cantidad de falsos positivos: hay 150 falsos positivos frente a 80 verdaderos positivos $\rightarrow$ $\text{precision} = 80 / (80 + 150) \approx 0.35$, lo cual es bajo. Sensibilidad es alta ($80/100 = 0.80$). La especificidad y accuracy no están tan deterioradas.

La respuesta correcta es: **Precisión (Precision)**

Información

[Marcar pregunta](#)

Para las siguientes preguntas debes emplear los datos que podrás descargar en de este enlace: [Datos](#)

Debes descargar los datos y luego puedes cargar los datos usando pandas:

```
import numpy as np
import pandas as pd

data=pd.read_csv('riesgo_cardiovascular.data')
```

Contexto:

En un estudio sobre riesgo cardiovascular se recolectaron datos de 500 personas con cinco variables:

1. Riesgo cardiovascular (0-100)
2. Horas de ejercicio semanal
3. Horas de sueño diarias
4. Tazas de café consumidas
5. Minutos en redes sociales

La variable objetivo es **Riesgo cardiovascular**, se espera que las demás variables tengan algún tipo de influencia en la variable objetivo. Debemos descubrir si en efecto existe tal relación.

Pregunta 16

[Marcar pregunta](#)**Incorrecta**

Se puntúa 0,00 sobre 3,00

Debes calcular la matriz de correlación empleando el coeficiente de correlación de **Pearson** para analizar la existencia de relaciones lineales entre variables. _____

Según la matriz de correlación ¿Cuál es la conclusión correcta?

- ☐ a. El café diario ($r = 0.094$) es un factor protector contra el riesgo cardiovascular.
- ☐ b. Las horas sueño ($r = 0.0089$) tienen mayor impacto en el riesgo que el ejercicio ($r = -0.012$).
- ☒ c. No hay relación alguna entre ejercicio y riesgo cardiovascular, pues la correlación es -0.012 (próxima a cero). ✗
- ☐ d. La correlación lineal no detecta relaciones no lineales; se debe usar un análisis de regresión cuadrática o modelos no lineales
- ☐ e. Ninguna de las opciones es correcta

Respuesta incorrecta.

Correlación de Pearson solo mide relaciones *lineales*. Una correlación cercana a cero (como 0.03) **no descarta relaciones no lineales**.

Para confirmar la relación, se debe:

1. Graficar los datos .
2. Calcular correlaciones no lineales (ej: coeficiente de Spearman para monotonía o mutual information).

La respuesta correcta es:

La correlación lineal no detecta relaciones no lineales; se debe usar un análisis de regresión cuadrática o modelos no lineales

Pregunta 17

[Marcar pregunta](#)

Correcta

Se puntúa 3,00 sobre 3,00

Contexto: Al calcular la matriz de correlación lineal (Pearson), ninguna variable muestra una correlación significativa ($|r| < 0.1$) con el riesgo cardiovascular. Sin embargo, se sospecha que podría haber relaciones no lineales ocultas.

Para identificar visualmente patrones no lineales y relaciones entre variables, ¿cuál es el siguiente paso más adecuado?

- ☐ a. **Descartar todas las variables**, ya que la correlación lineal no fue significativa.
- ☐ b. Ninguna de las opciones es correcta
- ☐ c. **Entrenar un modelo de regresión lineal** directamente, pues el modelo puede capturar patrones complejos en los datos sin necesidad de EDA.
- ☐ d. **Aplicar una transformación logarítmica** a todas las variables y recalculando la correlación de Pearson.
- ☒ e. **Generar un pairplot** (matriz de gráficos de dispersión y histogramas) para visualizar distribuciones y relaciones bivariadas. ✓

Respuesta correcta

Un `pairplot` (ej: con `seaborn.pairplot()`) permite:

- Visualizar la relación entre *todas las variables* en una sola matriz de gráficos.
- Identificar patrones **no lineales** (como la parábola entre `Horas_Ejercicio` y `Riesgo_Cardiovascular`).
- Detectar distribuciones anómalas o outliers.

La respuesta correcta es:

Generar un pairplot (matriz de gráficos de dispersión y histogramas) para visualizar distribuciones y relaciones bivariadas.

Pregunta 18

[Marcar pregunta](#)

Correcta

Se puntúa 3,00 sobre 3,00

Usando los datos proporcionados, realiza un `pairplot` para analizar visualmente las relaciones entre las variables: _____

'Horas_Sueno', 'Tazas_Cafe', 'Horas_Ejercicio', 'Minutos_Redes'


Y la variable objetivo: '**Riesgo_Cardiovascular**'

A partir del grafico realizado, podemos concluir que:


- ☒ a. Existe una relación parabólica oculta entre *Horas_Ejercicio* y *Riesgo_Cardiovascular* ✓
- ☐ b. Existe una relación lineal entre *Minutos_redes* y *Riesgo_Cardiovascular*
- ☐ c. Existe una relación lineal entre *Horas_Ejercicio* y *Riesgo_Cardiovascular*
- ☐ d. Existe una relación lineal oculta entre *Horas_Sueno* y *Riesgo_Cardiovascular*
- ☐ e. Existe una relación parabólica oculta entre *Tazas_Cafe* y *Riesgo_Cardiovascular*

Respuesta correcta

en el siguiente grafico podemos observar que la variable "Horas_ejercicio" tiene una relación parabólica con la variable objetivo:



Esto lo podemos corroborar usando un ajuste parabólico:



La respuesta correcta es:

Existe una relación parabólica oculta entre *Horas_Ejercicio* **y** *Riesgo_Cardiovascular*

Pregunta 19

[Marcar pregunta](#)**Incorrecta**

Se puntúa 0,00 sobre 3,00

Realizar el siguiente experimento:

- Seleccione únicamente la variable **Horas_Ejercicio** como variable predictora (X) y use la variable **Riesgo_Cardiovascular** como variable objetivo (y)
- Separar los datos en entrenamiento y prueba usando: `test_size=0.3, random_state=42`
- **Ajuste dos modelos** utilizando `sklearn` :
 - **Modelo 1:** Regresión lineal simple (grado 1).
 - **Modelo 2:** Regresión polinomial (grado 2):

```
from sklearn.preprocessing import PolynomialFeatures  
poly = PolynomialFeatures(degree=2)  
X_poly = poly.fit_transform(X_train)
```

- **Compare ambos modelos** mediante:
 - El **Error Cuadrático Medio (MSE)** en datos de prueba.

A partir de los resultados obtenidos podemos concluir que:

- ☐ a. El modelo polinomial (grado 2) obtiene un MSE menor que el lineal, ya que captura la relación parabólica observada en los datos. La regresión lineal simple es insuficiente para modelar patrones no lineales.
- ☒ b. El modelo polinomial (grado 2) tiene un MSE menor porque es más complejo, lo que demuestra que siempre debemos usar polinomios de alto grado para minimizar el error, sin importar la relación real en los datos. ✗
- ☐ c. El modelo polinomial es mejor porque su MSE es menor en los datos de prueba, lo que garantiza que funcionará igual de bien en cualquier otro conjunto de datos médico.
- ☐ d. La regresión lineal simple tiene un MSE más alto porque los datos no tienen ninguna relación con la variable independiente, lo que confirma que el ejercicio no influye en el riesgo cardiovascular.

Respuesta incorrecta.

El modelo polinomial (grado 2) obtiene un MSE menor que el lineal, ya que captura la relación parabólica observada en los datos. La regresión lineal simple es insuficiente para modelar patrones no lineales

La afirmación es **correcta** porque:

1. Los datos tienen una relación cuadrática (parábola).
2. El modelo polinomial (grado 2) tiene la flexibilidad necesaria para representarla.
3. El modelo lineal es rígido y no puede adaptarse a curvaturas.

"El modelo polinomial (grado 2) tiene un MSE menor porque es más complejo, lo que demuestra que siempre debemos usar polinomios de alto grado para minimizar el error, sin importar la relación real en los datos."

Es incorrecta: Asume que mayor complejidad siempre mejora el modelo, ignorando sobreajuste (*overfitting*). En realidad, el polinomio de grado 2 funciona mejor **solo** porque coincide con la relación parabólica real.

"La regresión lineal simple tiene un MSE más alto porque los datos no tienen ninguna relación con la variable independiente, lo que confirma que el ejercicio no influye en el riesgo cardiovascular."

Es incorrecta: El MSE alto en el modelo lineal se debe a que no captura la **relación no lineal**, no a la ausencia de relación. La parábola existe, pero el modelo lineal no puede representarla.

"El modelo polinomial es mejor porque su MSE es menor en los datos de prueba, lo que garantiza que funcionará igual de bien en cualquier otro conjunto de datos médico."

Es incorrecta: Un buen desempeño en un conjunto de prueba **no garantiza** generalización a otros contextos (p. ej., si los nuevos datos siguen una relación cúbica en lugar de cuadrática). Además, ignora posibles sesgos en los datos sintéticos.

La respuesta correcta es:

El modelo polinomial (grado 2) obtiene un MSE menor que el lineal, ya que captura la relación parabólica observada en los datos. La regresión lineal simple es insuficiente para modelar patrones no lineales.

Pregunta 20

[Marcar pregunta](#)

Correcta

Se puntúa 3,00 sobre 3,00

Al comparar un **modelo de regresión lineal simple** (grado 1) y un **modelo de regresión polinomial** (grado 2) para predecir el riesgo cardiovascular en función de las horas de ejercicio, se obtuvieron los siguientes errores cuadráticos medios (MSE) en datos de prueba: _____

- **MSE Lineal:** 42.64
- **MSE Polinomial:** 6.52

¿Cuál de las siguientes conclusiones es la más adecuada basada en estos resultados?

- ☐ a. El modelo lineal es superior porque, aunque tiene un MSE más alto, es más interpretable y generalizable.
- ☐ b. Ambos modelos son igualmente válidos, pues el MSE depende de la escala de los datos y no refleja diferencias reales en su capacidad predictiva.
- ☒ c. El modelo polinomial (grado 2) es claramente mejor, ya que su MSE es 6.5 veces menor que el del modelo lineal, lo que indica que captura la relación no lineal en los datos. ✓
- ☐ d. El MSE polinomial es sospechosamente bajo, lo que sugiere sobreajuste (overfitting); por tanto, el modelo lineal es más confiable."

Respuesta correcta

"El modelo polinomial (grado 2) es claramente mejor, ya que su MSE es 6.5 veces menor que el del modelo lineal, lo que indica que captura la relación no lineal en los datos."

Diferencia significativa en MSE:

Un MSE de **6.52 vs. 42.64** implica que el modelo polinomial reduce el error en un **85%** $[(42.64 - 6.52)/42.64]$, lo que es decisivo.

Esto solo ocurre si el polinomio (grado 2) coincide con la relación parabólica real de los datos.

La respuesta correcta es:

El modelo polinomial (grado 2) es claramente mejor, ya que su MSE es 6.5 veces menor que el del modelo lineal, lo que indica que captura la relación no lineal en los datos.

Información

[Marcar pregunta](#)

Responder las siguientes preguntas usando los datos proporcionados en este enlace: [DATOS](#)

Debes descargar el archivo y luego cargar los datos usando pandas

En el archivo encontraras las etiquetas coorrectas <Real_Label>, los scores predichos por un clasificador <Predicted_Score> y la etiqueta predicha <Predicted_label>. Todos los valores fueron calculados usando un clasificador. Debes responder las siguientes preguntas usando la información contenida en el archivo. Los encabezados del archivo son : 'Real_Label' 'Predicted_Score' 'Predicted_label'

Puedes cargar los datos empleando pandas :

Debes darle descargar el archivo y puedes cargar los datos usando pandas

```
import pandas as pd  
df=pd.read_csv('predicciones_scores.data')
```





Pregunta 21

[Marcar pregunta](#)

Correcta

Se puntúa 3,00 sobre 3,00

Usando los scores proporcionados, debes graficar la curva ROC y seleccionar la opción correcta.



La curva roc de los datos proporcionados corresponde a:

☐ a. Ninguna de las opciones es correcta

☐ b. Clasificador 4

- ☐ c. Clasificador 2
- ☒ d. Clasificador 1 ✓
- ☐ e. Clasificador 3

Respuesta correcta

```
from sklearn.metrics import roc_curve, auc
```

```
# Calcular la curva ROC
```

```
fpr, tpr, thresholds = roc_curve(df["y_test"], df["y_scores"])
```

```
roc_auc = auc(fpr, tpr)
```

```
# Graficar la curva ROC
```

```
plt.figure()
```

```
plt.plot(fpr, tpr, color='darkorange', lw=2, label=f'ROC curve (area = {roc_auc:.2f})')
```

```
plt.plot([0, 1], [0, 1], color='navy', lw=2, linestyle='--')
```

```
plt.xlim([0.0, 1.0])
```

```
plt.ylim([0.0, 1.05])
```

```
plt.xlabel('Tasa de Falsos Positivos')
```

```
plt.ylabel('Tasa de Verdaderos Positivos')
```

```
plt.title('Curva ROC')
```

```
plt.legend(loc='lower right')
```

```
plt.show()
```

La respuesta correcta es: **Clasificador 1**

Pregunta 22

[Marcar pregunta](#)**Correcta**

Se puntúa 3,00 sobre 3,00

La métrica **Accuracy** es:

- ☒ a. 80% ✓
- ☐ b. 79%
- ☐ c. Ninguna de las opciones es correcta
- ☐ d. 89%
- ☐ e. 90%

Respuesta correcta

```
from sklearn.metrics import accuracy_score  
accuracy = accuracy_score(df["y_test"], df["y_pred"] )  
print(f"Accuracy: {accuracy:.2f}")
```

La respuesta correcta es: **80%**

Pregunta 23

[Marcar pregunta](#)**Correcta**

Se puntúa 3,00 sobre 3,00

La métrica **Precision** es:

- ☐ a. 95%
- ☐ b. 60%
- ☐ c. Ninguna de las opciones es correcta
- ☒ d. 89% ✓
- ☐ e. 79%

Respuesta correcta

```
from sklearn.metrics import precision_score  
precision = precision_score(df["y_test"], df["y_pred"] )  
print(f"Precision: {precision:.2f}")
```

La respuesta correcta es: **89%**

Pregunta 24

[Marcar pregunta](#)**Correcta**

Se puntúa 3,00 sobre 3,00

La métrica **Recall** es:

- ☒ a. 63% ✓
- ☐ b. Ninguna de las opciones es correcta
- ☐ c. 93%
- ☐ d. 73%
- ☐ e. 69%

Respuesta correcta

```
from sklearn.metrics import recall_score  
recall = recall_score(df["y_test"], df["y_pred"] )  
print(f"Recall: {recall:.2f}")
```

La respuesta correcta es: **63%**

Pregunta 25

[Marcar pregunta](#)

Correcta

Se puntúa 3,00 sobre 3,00

Verdadero o Falso - El número de falsos negativos es mayor que el de falsos positivos.

☒ Verdadero ✓☐ Falso

Debes calcular la matriz de confusión y luego comparar las cantidades

```
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay
```

```
# 1. Calcular la matriz de confusión
```

```
cm = confusion_matrix(df["y_test"], df["y_pred"] )
```

```
disp = ConfusionMatrixDisplay(confusion_matrix=cm)
```

```
disp.plot(cmap=plt.cm.Blues)
```

```
plt.title("Matriz de Confusión")
```

```
plt.show()
```

```
false_negatives = cm[1, 0] # Clase positiva clasificada como negativa
```

```
false_positives = cm[0, 1] # Clase negativa clasificada como positiva
```

```
# Pregunta
```

```
print("Pregunta : Verdadero o Falso - El número de falsos negativos es mayor que el  
de falsos positivos.")
```

```
print(f"Respuesta: {'Verdadero' if false_negatives > false_positives else 'Falso'})
```

La respuesta correcta es 'Verdadero'

Pregunta 26

[Marcar pregunta](#)

Correcta

Se puntúa 3,00 sobre 3,00

Verdadero o Falso - El clasificador identificó correctamente más de 85% de las instancias de la clase negativa.

☒ Verdadero ✓☐ Falso

Debe calcular la matriz de confusión y luego calcular la relación entre los verdaderos negativos y el total de instancias negativas que hay en la base de datos.

```
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay
# 1. Calcular la matriz de confusión
cm = confusion_matrix(df["y_test"], df["y_pred"])
disp = ConfusionMatrixDisplay(confusion_matrix=cm)
disp.plot(cmap=plt.cm.Blues)
plt.title("Matriz de Confusión")
plt.show()
```

```
TN = cm[0, 0]
total_Negatives = sum(df["y_test"]==0)
print("Pregunta : Verdadero o Falso - El clasificador predijo correctamente más del
85% de las instancias de la clase negativa")
correct_percentage = (TN / total_Negatives) * 100
print(f"Respuesta: {'Verdadero' if correct_percentage > 85 else 'Falso'})"
```

La respuesta correcta es 'Verdadero'

Información

[Marcar pregunta](#)

Responder las siguientes preguntas usando los datos proporcionados en los siguientes enlaces: [Conjunto de prueba](#), Conjunto de [entrenamiento](#)

Con los dos conjuntos de datos: **train** y **test**. Debe entrenar un clasificador KNN y un modelo de regresión logística para responder las siguientes preguntas.

Como puede notar, los datos ya están separados en entrenamiento y prueba, por lo que no es necesario que aplique de nuevo una partición.

Pregunta 27

[Marcar pregunta](#)**Correcta**

Se puntúa 2,00 sobre 2,00

Verdadero o Falso - Los datos tienen igual proporción de registros (instancias) de cada clase. Son clases balanceadas.

☐ Verdadero☒ Falso ✓

```
df_train=pd.read_csv('train_set.csv')
X_train = df_train.drop(columns=['target']) # Drop target column to create
features
y_train = df_train['target'] # Target variable
```

```
df_test=pd.read_csv('test_set.csv')
X_test = df_test.drop(columns=['target']) # Drop target column to create features
y_test = df_test['target'] # Target variable
#total de cada clase
print(sum(y_train==1))
print(sum(y_train==0))
```

```
print(sum(y_train==0))
```

La respuesta correcta es 'Falso'

Pregunta 28

[Marcar pregunta](#)

Incorrecta

Se puntúa 0,00 sobre 3,00

El mejor valor de **K - vecinos** y su respectivo **accuracy** para el clasificador KNN es:

- ☐ a. **K=5**, con un **accuracy**= 80%
- ☒ b. **K=7**, con un **accuracy**= 95% ✖
- ☐ c. **K=3**, con un **accuracy**= 90%
- ☐ d. **K=3**, con un **accuracy**= 92%
- ☐ e. **K=5**, con un **accuracy**= 70%

Respuesta incorrecta.

```
from sklearn.neighbors import KNeighborsClassifier  
from sklearn.metrics import accuracy_score
```

```
# usar solamente KNN
```

```
#Inicializar variables
```

```
best_k = 1
```

```
best_accuracy = 0
```

```
accuracies = []
```

```
# Probar valores de k de 1 a 9
```

```
for k in range(1, 10):
```

```
    # Entrenar el modelo KNN con k vecinos
```

```
    knn = KNeighborsClassifier(n_neighbors=k)
```

```
    knn.fit(X_train, y_train)
```

```
# Predecir las etiquetas para X_test
y_pred = knn.predict(X_test)

# Calcular la exactitud
accuracy = accuracy_score(y_test, y_pred)
accuracies.append(accuracy)

# Verificar si este k es el mejor
if accuracy > best_accuracy:
    best_accuracy = accuracy
    best_k = k

print(f"El mejor valor de k es: {best_k} con una exactitud de: {best_accuracy:.2f}")

# Mostrar las exactitudes para cada valor de k
for k in range(1, 10):
    print(f"k = {k}: Exactitud = {accuracies[k-1]:.2f}")
```

La respuesta correcta es: **K=3, con un accuracy= 92%**

Pregunta 29

[Marcar pregunta](#)

Correcta

Se puntúa 3,00 sobre 3,00

Usando **K=7**, el número de falsos positivos es:

- ☐ a. 177
- ☐ b. Ninguna de las opciones es correcta
- ☐ c. 158
- ☒ d. 8 ✓
- ☐ e. 17

Respuesta correcta

```
knn = KNeighborsClassifier(n_neighbors=7)
knn.fit(X_train, y_train)
```

```
# Predecir las etiquetas para X_test
y_pred = knn.predict(X_test)
cm = confusion_matrix(y_test, y_pred)
print(cm)
```

La respuesta correcta es: **8**

Pregunta 30

[Marcar pregunta](#)**Correcta**

Se puntúa 3,00 sobre 3,00

Usando un modelo de regresión logística, selecciona los parámetros del modelo que más se aproximen a su estimación.

Nota: No es necesario normalizar los datos

- ☒ a. Coeficientes: -0.325, 1.433, Intercepto : -0.120 ✓
- ☐ b. Coeficientes: -0.425, 0.433, Intercepto : -0.126
- ☐ c. Coeficientes: -2.325, 3.433, Intercepto : -1.120
- ☐ d. Coeficientes: -0.999, 1.667, Intercepto : 0.120
- ☐ e. Coeficientes: 0.325, 1.433, Intercepto : 0.120

Respuesta correcta

```
from sklearn.linear_model import LogisticRegression
# Entrenar solamente un modelo de regresión logística
model = LogisticRegression()
model.fit(X_train, y_train)
print(model.coef_)
print(model.intercept_)
```

La respuesta correcta es: **Coeficientes: -0.325, 1.433, Intercepto : -0.120**

[Finalizar revisión](#)