

1

Predicción y Clasificación en la Industria Azucarera

Victor Quijano Vidal
Anderson Pipicano Ruiz
Andres Cuellar Pachon

Resumen: Este estudio presenta el desarrollo de modelos de inteligencia artificial orientados a la industria azucarera del Ingenio Providencia, con el fin de optimizar la productividad y la calidad de la caña de azúcar. Se abordaron dos objetivos estratégicos: la predicción de TCH (Toneladas de Caña por Hectárea) como indicador de rendimiento y la estimación de %Sac.Caña (Porcentaje de Sacarosa en Caña) como medida de calidad industrial. El flujo metodológico incluyó un análisis exploratorio de datos (EDA) para detectar patrones y variables relevantes, seguido de la implementación de pipelines de preprocesamiento con imputación, escalado y codificación categórica. Posteriormente, se entrenaron y compararon tres modelos de regresión: Ridge y Lasso. Los resultados evidenciaron que los métodos basados en ensambles de árboles alcanzaron mayor precisión y estabilidad, identificando como factores clave la variedad de caña, la edad del cultivo, las lluvias durante el ciclo y los indicadores de maduración.

En la segunda etapa, se desarrolló un sistema de clasificación que transformó las variables continuas TCH y %Sac.Caña en categorías de desempeño alto, medio y bajo mediante umbrales definidos a partir de percentiles. Se evaluaron modelos de K-means, Regresión Logística y Random Forest, analizando su desempeño con métricas como exactitud, precisión, recall, F1-score. En conclusión, la combinación de regresión y clasificación proporciona una herramienta integral para que el Ingenio Providencia anticipe su productividad, clasifique

de manera efectiva los lotes y fortalezca la toma de decisiones estratégicas en la gestión agrícola.

I. INTRODUCCIÓN

La optimización del rendimiento de los cultivos es un pilar fundamental en la industria azucarera moderna. La capacidad de predecir la productividad y la calidad de la caña antes de la cosecha permite una planificación logística y de recursos más eficiente. Este proyecto aborda este desafío en el Ingenio Providencia, utilizando datos históricos para construir modelos predictivos.

La base de cualquier modelo reside en la calidad de sus datos, por lo que se realizó un riguroso proceso de ingeniería de características para preparar la información y convertirla en un activo estratégico.

II. PARTE I: MODELO DE REGRESIÓN

Para el previo desarrollo del modelo predictivo reside en la calidad de sus datos, partiendo del archivo **HISTÓRICO SUERTES.xlsx**, realizamos el análisis exploratorio de los datos para convertir la información histórica en un activo estratégico.

- **Calidad de Datos Garantizada:** Se implementaron técnicas avanzadas para manejar valores faltantes, asegurando que cada registro aportará información confiable.
- **Codificación de las variables:** Variables claves cualitativas como la **Variedad** de caña fueron traducidas a un formato numérico (*One-Hot Encoding*), permitiendo al modelo comprender su impacto en el rendimiento.
- **Estandarización de Características:** Todas las características numéricas fueron estandarizadas, un paso fundamental para que algoritmos modernos operen con su máximo potencial.

Se realizó un análisis exploratorio para comprender a fondo las variables y sus interacciones. Se analizaron las distribuciones de las variables objetivo (TCH y % Sacarosa) y se generó un mapa de calor para detectar la multicolinealidad entre variables, justificando el

1

uso de modelos como Regresión Ridge, diseñado para manejar estas interdependencias.




Fig. 1. Gráfica distribución de TCH.

La distribución de **TCH** nos muestra una concentración de la productividad alrededor de las 120-140 Ton/Ha, identificando el rango de rendimiento más común en los cultivos.




Fig. 2. Gráfica distribución de Sac.Caña.

El Sac.Caña muestra una distribución normal y consistente, lo que indica una estabilidad en la calidad de la materia prima, un factor clave para la producción de azúcar.

Para entender qué factores impactan más en el rendimiento, generamos un mapa de calor. Este análisis visual fue clave para detectar relaciones complejas y la presencia de multicolinealidad (variables que se influyen entre sí)




Fig. 3. Gráfica Matriz de correlación variables numéricas.

Este hallazgo justifica nuestra elección de un modelo avanzado como **Regresión Ridge**, diseñado específicamente para manejar estas interdependencias y entregar predicciones estables y fiables ya que podemos encontrar variables con un relación alta y que pueden tener un impacto negativo en el modelo.

No basta con construir un modelo; es imperativo certificar su precisión. Utilizamos **validación cruzada de 5 folds**, una técnica rigurosa que simula el comportamiento del modelo con datos futuros. Los resultados directos del notebook hablan por sí solos

A. Predicción de Productividad (TCH)

Se realiza una evaluación comparativa del rendimiento y la estabilidad de los modelos de regresión **Ridge (L2)** y **Lasso (L1)** mediante validación cruzada ($k=5$).

El modelo **Ridge** obtiene un rendimiento promedio ligeramente superior en ambas métricas clave: presenta un Coeficiente de Determinación (R2) más alto (0.791 vs. 0.780) y un error promedio (RMSE) menor (13.95 vs. 14.37). Esto sugiere que, en promedio, sus predicciones son marginalmente más precisas que las del modelo Lasso.

Ambos modelos exhiben una inestabilidad considerable, como lo demuestra la alta desviación estándar en sus métricas y la presencia

de un "fold" con un rendimiento anómalamente bajo ($R^2 \approx 0.52$) en ambos casos. No obstante, el modelo **Lasso** muestra una desviación estándar consistentemente menor en sus métricas (R^2 : 0.130 vs. 0.134; RMSE: 3.88 vs. 4.06), lo que indica una varianza ligeramente inferior y, por ende, una estabilidad marginalmente mejor.

Ambos modelos muestran un rendimiento y una estabilidad muy similares, con una clara evidencia de alta varianza. La elección entre ellos no es definitiva basándose únicamente en estas métricas, si el objetivo principal es maximizar la **precisión predictiva**, el modelo **Ridge** presenta una ligera ventaja o si se prioriza la **consistencia y robustez** del modelo ante diferentes subconjuntos de datos, **Lasso** es marginalmente preferible.

B. Predicción de Productividad (porcentaje sacarosa de caña)

Se evaluó y comparó el rendimiento de los modelos **Ridge (L2)** y **Lasso (L1)** mediante validación cruzada ($k=5$). En este escenario, el modelo Ridge demuestra una superioridad clara y consistente sobre el modelo Lasso.

El modelo **Ridge es marcadamente superior**. Su Coeficiente de Determinación (R^2) promedio (0.372) casi duplica al de Lasso (0.194), indicando que explica una porción mucho mayor de la variabilidad de los datos. Adicionalmente, su error promedio (RMSE) de 0.87 es significativamente más bajo que el de Lasso (0.98).

El modelo **Ridge también es más estable**. Su desviación estándar en el R^2 (0.099) es considerablemente menor que la de Lasso (0.143). Esto se confirma al observar los resultados por fold del modelo Lasso ([0.011, 0.032, ...]), que muestran un rendimiento extremadamente errático y poco fiable. La única métrica donde Lasso muestra una ligera ventaja es en la consistencia de su error (menor desv. estándar del RMSE), pero esto es irrelevante dado su bajo rendimiento general.

A diferencia del análisis anterior donde los modelos eran comparables, en este caso la elección es definitiva.

El **modelo Ridge es inequívocamente superior** en todos los aspectos críticos: ofrece una

mayor precisión predictiva, un error significativamente menor y una estabilidad considerablemente mayor. El rendimiento del modelo Lasso es deficiente y su alta varianza lo hace inviable para una aplicación práctica en este problema.

Para evolucionar esta solución y convertirla en un sistema de inteligencia agrícola integral, proponemos el **Enriquecimiento de Datos (Data Enrichment)**: La mejora más significativa provendrá de la incorporación de nuevas fuentes de datos como la instalación de sensores de humedad, pH y nutrientes en el suelo proporciona datos granulares para entender el rendimiento a un nivel de detalle sin precedentes.

El modelo de Regresión Ridge implementado es un **activo estratégico** que posiciona al Ingenio Providencia a la vanguardia de la agricultura de precisión. La capacidad de anticipar con una fiabilidad en la productividad y la calidad de la caña permite pasar de una gestión reactiva a una **estrategia proactiva**. Esto se traduce directamente en una optimización de recursos, una mejor planificación logística y, en última instancia, una ventaja competitiva sostenible en el mercado.

III. PARTE 2: MODELO DE CLASIFICACIÓN

El análisis partió de un conjunto de datos **BD IPSA 1940.xlsx** con 2187 registros y 21 variables de la industria azucarera. Las variables objetivo, TCH y sacarosa, se utilizaron para crear categorías de rendimiento (Bajo, Medio, Alto) definidas por los percentiles 33 y 67 de sus distribuciones. Adicionalmente, se generó una métrica de "Desempeño Combinado" que clasifica los registros en cinco niveles: Excelente, Bueno, Regular, Mixto y Deficiente.

Las distribuciones de las variables TCH y Sacarosa_Porcentaje mostraron una ligera asimetría, y el análisis de correlación indicó una relación inversa débil (-0.207) entre ambas, sugiriendo un posible compromiso entre la cantidad de caña y su calidad en términos de sacarosa.

Resultados de los Modelos de Clasificación

Se implementaron y evaluaron tres modelos distintos para abordar el problema desde diferentes perspectivas:

1. K-means (Clustering no supervisado)

Como análisis exploratorio, el método K-means identificó que la estructura natural de los datos se agrupa de manera óptima en dos clústeres. Estos grupos mostraron una clara separación:

- Un clúster con TCH alto y sacarosa baja.
- Un clúster con TCH más bajo y sacarosa más alta.

Este resultado refuerza la idea de un trade-off entre el volumen de producción (toneladas) y la concentración de sacarosa.

2. Regresión Logística (Clasificación supervisada)

Este modelo se utilizó para predecir la categoría de "Desempeño Combinado". Alcanzó una precisión general del 72.1%. Aunque su rendimiento es bueno para las clases mayoritarias como "Bueno", su principal ventaja radica en la alta interpretabilidad, permitiendo entender qué factores influyen más en la clasificación.

3. Random Forest (Clasificación supervisada)

El modelo Random Forest superó a la Regresión Logística, logrando una precisión del 77.6% en la predicción de la misma variable objetivo. Su fortaleza es la capacidad predictiva superior, aunque es menos interpretable que el modelo logístico. El análisis de la matriz de confusión demostró su eficacia, especialmente en la identificación correcta de las categorías "Bueno" y "Mixto".

A nivel gráfico, el ejercicio arroja información que denota que la distribución es prácticamente uniforme, donde se puede observar que la variabilidad en las variables fundamentales se encuentra correctamente capturada en el dataset




Fig. 4. Gráfica Patrones de Clustering Resultado de clasificación.

Se puede observar en la figura que la variable TCH oscila entre 0-250 toneladas por hectárea, con una concentración significativa en el rango de 50-150 t/ha, lo que es consistente con los rendimientos típicos de caña de azúcar en condiciones comerciales.

Similar al TCH, la distribución es equilibrada, indicando una buena representación de la calidad del contenido azucarero. El rango de %Sac.Caña (9-16%) es típico para caña de azúcar comercial.




Fig. 5. Matriz de confusión resultante

La matriz de confusión revela que, por una parte, valores más altos se observan en las intersecciones Medio-Medio (272) y Medio-Alto (268), lo que posiblemente puede indicarnos que la mayoría de las muestras presentan rendimientos y calidad intermedios.

Por otra parte, la distribución sugiere que TCH y %Sac.Caña tienen cierta independencia, importante para estrategias de mejoramiento diferenciadas. Finalmente, se puede observar que no hay una categoría dominante excesiva, lo que indica una clasificación correcta sin que se hayan presentado sesgos significativos.

IV. CONCLUSIONES

El análisis ha demostrado ser exitoso en la creación y predicción de categorías de desempeño para variables clave en la industria azucarera. Se concluye que no existe un único "mejor" modelo, sino que la elección depende del caso de uso específico.

La evaluación comparativa de los modelos permite ofrecer recomendaciones específicas según el objetivo de negocio:

- Para máxima precisión predictiva: Se recomienda utilizar el modelo de Random Forest, ya que ofrece el mejor rendimiento global (77.6%). Es ideal para aplicaciones donde el resultado de la predicción es el factor más crítico.
- Para interpretabilidad y explicabilidad: La Regresión Logística es una buena opción. Es adecuada cuando es necesario explicar las decisiones del modelo a los responsables del negocio o para entender los factores clave que determinan el rendimiento.
- Para descubrimiento de patrones y segmentación: K-means es la técnica idónea para explorar agrupaciones naturales en los datos sin etiquetas predefinidas. Puede ser utilizado para segmentar campos o proveedores en grupos con características de rendimiento similares, facilitando la gestión personalizada.

El ejercicio permitió reforzar conceptos referentes a los diferentes algoritmos existentes en materia de clasificación de datos, dando un panorama claro de la diversidad de soluciones para los respectivos casos de uso presentes en la industria.

V. REFERENCIAS

- [1] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York: Springer, 2009.
- [2] R. A. C. Filho, E. A. Poz, and G. A. S. Ferraz, "Sugarcane yield prediction using machine learning: A case study in Brazil," *Computers and Electronics in Agriculture*, vol. 185, p. 106149, 2021.
- [3] A. E. Hoerl and R. W. Kennard, "Ridge regression: Biased estimation for nonorthogonal problems," *Technometrics*, vol. 12, no. 1, pp. 55-67, 1970.
- [4] S. S. S. Kumar and K. R. S. Kumar, "A survey on precision agriculture using IoT and machine learning," in *2021 5th International Conference on Computing Methodologies and Communication (ICCMC)*, 2021, pp. 1198-1204.
- [5] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.