



Comenzado el

viernes, 29 de agosto de 2025, 22:12

Estado

Finalizado

Finalizado en

viernes, 29 de agosto de 2025, 22:42

Tiempo empleado

29 minutos 22 segundos

Puntos

21,00/33,00

Calificación

3,18 de 5,00 (63,64%)

Pregunta 1

[Marcar pregunta](#)**Correcta**

Se puntúa 1,00 sobre 1,00

¿Cuál es la principal diferencia entre la regresión Ridge y la regresión Lasso en cuanto a la selección de variables?

- ☒ a. Lasso elimina variables irrelevantes asignándoles coeficiente exactamente cero. ✓
- ☐ b. Ninguno de las opciones es correcta
- ☐ c. Ridge elimina variables irrelevantes asignándoles coeficiente exactamente cero.
- ☐ d. Ambos métodos eliminan variables de forma similar

Respuesta correcta

La regresión Ridge utiliza una penalización L2 que reduce continuamente los coeficientes pero nunca los lleva exactamente a cero, mientras que la regresión Lasso utiliza una penalización L1 que puede forzar algunos coeficientes a ser exactamente cero, realizando así selección de variables.

La respuesta correcta es:

Lasso elimina variables irrelevantes asignándoles coeficiente exactamente cero.

Pregunta 2

[Marcar pregunta](#)**Correcta**

Se puntúa 1,00 sobre 1,00

¿Cuál de las siguientes definiciones corresponde a la exactitud (accuracy) en un modelo de clasificación? _____

- ☐ a. La proporción de verdaderos positivos sobre el total de casos positivos.
- ☐ b. La proporción de falsos negativos sobre el total de casos negativos
- ☒ c. La proporción de predicciones correctas (suma de verdaderos positivos y verdaderos negativos) sobre el total de casos. ✓
- ☐ d. La diferencia entre precisión y recall.

Respuesta correcta

La exactitud se define como el número de predicciones correctas dividido por el total de predicciones, es decir, la suma de verdaderos positivos y verdaderos negativos dividido entre el total de casos.

La respuesta correcta es:

La proporción de predicciones correctas (suma de verdaderos positivos y verdaderos negativos) sobre el total de casos.

Pregunta 3

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

¿Cómo se define el recall (sensibilidad) en el contexto de la clasificación binaria?

- ☐ a. Ninguna de las opciones es correcta
- ☒ b. $recall = \frac{VP}{VP+FN}$ ✓
- ☐ c. $recall = \frac{VP+VN}{VP+VN+FP+FN}$
- ☐ d. $recall = \frac{VN}{VN+FP}$
- ☐ e. $recall = \frac{VP}{VP+FP}$

Respuesta correcta

El recall se define como la proporción de verdaderos positivos (VP) sobre la suma de verdaderos positivos y falsos negativos (FN), indicando la capacidad del modelo para identificar correctamente los casos positivos

La respuesta correcta es: $recall = \frac{VP}{VP+FN}$

Pregunta 4

[Marcar pregunta](#)**Correcta**

Se puntúa 1,00 sobre 1,00

¿Qué métrica se priorizaría en un escenario donde los falsos negativos tienen un costo significativamente mayor que los falsos positivos, por ejemplo, en la detección temprana de una enfermedad?_____

- ☒ a. Recall (sensibilidad) ✓
- ☐ b. Precisión (precision)
- ☐ c. Exactitud (accuracy)
- ☐ d. F1 score

Respuesta correcta

Cuando es crucial detectar todos los casos positivos (minimizando falsos negativos), se prioriza el recall, ya que mide la capacidad del modelo para identificar correctamente los positivos.

La respuesta correcta es: **Recall (sensibilidad)**

Pregunta 5

[Marcar pregunta](#)**Correcta**

Se puntúa 1,00 sobre 1,00

Si un clasificador presenta una alta exactitud pero un bajo recall para la clase positiva, ¿qué se puede inferir? _____

- ☐ a. El modelo presenta un buen equilibrio entre precisión y recall.
- ☐ b. El modelo tiene alta precisión en la clase positiva.
- ☐ c. El modelo detecta correctamente casi todos los casos positivos
- ☒ d. El modelo omite muchos casos positivos (alta tasa de falsos negativos). ✓

Respuesta correcta

Un bajo recall indica que el modelo no identifica la mayoría de los casos positivos, lo que se traduce en un elevado número de falsos negativos, aun cuando la exactitud global sea alta por el predominio de la clase negativa.

La respuesta correcta es:

El modelo omite muchos casos positivos (alta tasa de falsos negativos).

Pregunta 6

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

En un modelo de clasificación, si se observa que la precisión es alta pero el recall es bajo, ¿qué conclusión se puede extraer?_____

- ☐ a. El modelo identifica correctamente casi todos los casos positivos.
- ☒ b. El modelo clasifica como positivos únicamente aquellos casos en los que está muy seguro, lo que genera muchos falsos negativos. ✓
- ☐ c. El modelo presenta una alta tasa de falsos positivos.
- ☐ d. El modelo tiene un buen equilibrio entre identificar positivos y evitar falsos positivos.

Respuesta correcta

Una alta precisión junto con un bajo recall indica que, aunque las predicciones positivas sean mayoritariamente correctas, el modelo omite muchos casos positivos reales (resultando en numerosos falsos negativos).

La respuesta correcta es:

El modelo clasifica como positivos únicamente aquellos casos en los que está muy seguro, lo que genera muchos falsos negativos.

Pregunta 7

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

¿Qué forma tiene el término de penalización en la regresión Ridge? _____

- ☐ a. $\lambda \sum_{j=1}^p \beta_j$
- ☒ b. $\lambda \sum_{j=1}^p \beta_j^2$ ✓
- ☐ c. Ninguna de las opciones es correcta
- ☐ d. $\lambda \sum_{j=1}^p \|\beta_j\|$

Respuesta correcta

En Ridge se penaliza la suma de los cuadrados de los coeficientes, lo que corresponde al término $\lambda \sum_{j=1}^p \beta_j^2$.

La respuesta correcta es: $\lambda \sum_{j=1}^p \beta_j^2$

Pregunta 8

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

¿Qué forma tiene el término de penalización en la regresión Lasso?

- ☒ a. $\lambda \sum_{j=1}^p |\beta_j|$ ✓
- ☐ b. $\lambda \sum_{j=1}^p \beta_j^2$
- ☐ c. $\lambda \sum_{j=1}^p \beta_j$
- ☐ d. Ninguna de las opciones es correcta

Respuesta correcta

La regresión Lasso utiliza la norma L1, penalizando la suma de los valores absolutos de los coeficientes, es decir, $\lambda \sum_{j=1}^p |\beta_j|$.

La respuesta correcta es: $\lambda \sum_{j=1}^p |\beta_j|$

Pregunta 9

[Marcar pregunta](#)**Correcta**

Se puntúa 1,00 sobre 1,00

¿Qué efecto tiene aumentar el parámetro de regularización λ en ambos métodos?

- ☐ a. Aumenta la magnitud de los coeficientes en ambos métodos.
- ☐ b. Solo afecta a Ridge, no a Lasso.
- ☐ c. No tiene efecto en la magnitud de los coeficientes.
- ☒ d. Disminuye la magnitud de los coeficientes y, en el caso de Lasso, puede anular algunos. ✓

Respuesta correcta

Al incrementar λ se aumenta la penalización. En Ridge, los coeficientes se reducen de manera proporcional pero siguen siendo distintos de cero; en Lasso, además de reducirse, algunos coeficientes pueden llegar a ser exactamente cero, realizando selección de variables.

La respuesta correcta es:

Disminuye la magnitud de los coeficientes y, en el caso de Lasso, puede anular algunos.

Pregunta 10

[Marcar pregunta](#)**Correcta**

Se puntúa 1,00 sobre 1,00

¿Cuál de los siguientes escenarios es más adecuado para utilizar la regresión Ridge?

- ☐ a. Ninguna de las opciones es correcta.
- ☐ b. Cuando se espera que solo unas pocas variables sean relevantes.
- ☒ c. Cuando se cuenta con muchos predictores y se espera que todos tengan cierta contribución. ✓
- ☐ d. Cuando se requiere eliminar variables redundantes

Respuesta correcta

Ridge es preferible cuando se cree que la respuesta depende de muchas variables, ya que reduce la varianza sin eliminar ninguna variable del modelo. _____

La respuesta correcta es:

Cuando se cuenta con muchos predictores y se espera que todos tengan cierta contribución.

Pregunta 11

[Marcar pregunta](#)**Correcta**

Se puntúa 1,00 sobre 1,00

¿Por qué es importante estandarizar los predictores antes de aplicar técnicas de regularización? _____

- ☐ a. Ninguna de las opciones es correcta.
- ☒ b. Porque la regularización es sensible a la escala de los predictores ✓
- ☐ c. Porque estandarizar reduce el número de predictores.
- ☐ d. Porque se mejora la interpretabilidad de la variable respuesta

Respuesta correcta

La magnitud de la penalización depende de la escala de cada predictor; al estandarizarlos (restar la media y dividir por la desviación estándar) se asegura que todos contribuyan de forma equitativa al término de penalización.

La respuesta correcta es:

Porque la regularización es sensible a la escala de los predictores

Pregunta 12

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Ordene los siguientes pasos para ajustar un modelo regularizado utilizando validación cruzada: _____

- ✓ Seleccionar un conjunto de valores para λ .
- ✓ Calcular el error de validación para cada valor de λ .
- ✓ Escoger el λ que minimice el error de validación.
- ✓ Reajustar el modelo con todos los datos usando el λ seleccionado

Respuesta correcta

Primero se define una grilla de valores para λ , luego se evalúa el rendimiento del modelo mediante validación cruzada para cada valor, se selecciona el λ que minimiza el error de validación y finalmente se reajusta el modelo con el valor óptimo usando todos los datos.

Pregunta 13

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

La matriz de confusión muestra únicamente los verdaderos positivos y verdaderos negativos de un modelo. _____

☐ Verdadero☒ Falso ✓

La matriz de confusión incluye los verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos, ofreciendo una visión completa de los aciertos y errores del modelo.

La respuesta correcta es 'Falso'

Pregunta 14

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

La exactitud (accuracy) es una métrica adecuada cuando se trabaja con conjuntos de datos balanceados. _____

☒ Verdadero ✓

☐ Falso

En conjuntos de datos balanceados, la exactitud refleja de manera adecuada el desempeño del modelo, ya que no existe un sesgo fuerte hacia ninguna de las clases.

La respuesta correcta es 'Verdadero'

Pregunta 15

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

En la regresión Ridge, todos los predictores permanecen en el modelo sin importar el valor de λ . _____

☒ Verdadero ✓

☐ Falso

La penalización L2 de Ridge reduce la magnitud de los coeficientes, pero nunca los anula completamente, por lo que todos los predictores se mantienen en el modelo.

La respuesta correcta es 'Verdadero'

Información

[Marcar pregunta](#)

Para las siguientes preguntas debes cargar el dataset **"credit-g"** utilizando `fetch_openml()`. Este conjunto de datos contiene información sobre solicitudes de crédito, donde la variable objetivo indica si el crédito es `good` o `bad`.

Detalles: https://www.openml.org/search?type=data&sort=version&status=any&order=asc&exact_name=credit-g&id=31

Transformación:

Se transforma la variable objetivo a formato numérico incluída la columna "class":

- 1 para "good"
- 0 para "bad"

Puedes usar el siguiente código para preparar tu entorno y cargar el dataset en tu entorno:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.datasets import fetch_openml
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import (classification_report, confusion_matrix, accuracy_score,
                             precision_score, recall_score, f1_score, roc_curve, auc)
```

```
# Cargar el dataset
credit = fetch_openml('credit-g', version=1, as_frame=True)
# credit.frame contiene todas las columnas
df = credit.frame
```

Pregunta 16

[Marcar pregunta](#)**Correcta**

Se puntúa 2,00 sobre 2,00

Cual de las siguientes afirmaciones es correcta: _____

- ☐ a. El dataset contiene 900 registros con 21 variables predictoras.
- ☒ b. El dataset contiene 1000 registros con 20 variables predictoras, para un total de 21 al incluir la variable objetivo. _____ ✓
- ☐ c. El dataset contiene 20 registros con 1000 variables predictoras, para un total de 1001 al incluir la variable objetivo.
- ☐ d. El dataset contiene 21 registros con 900 variables predictoras, para un total de 9001 al incluir la variable objetivo.

Respuesta correcta

Visualizar la forma del dataset

```
print("Forma del dataframe:", df.shape)
```

Forma del dataframe: (1000, 21)

Incluye la columna class

La respuesta correcta es:

El dataset contiene 1000 registros con 20 variables predictoras, para un total de 21 al incluir la variable objetivo. _____

Pregunta 17

[Marcar pregunta](#)**Correcta**

Se puntúa 2,00 sobre 2,00

La siguiente línea de código permite hacer la transformación necesaria para poder implementar el modelado:

Transforma la variable objetivo a formato numérico:

- 1 para "good"
- 0 para "bad"

- ☒ a. `df['class'] = df['class'].map({'good': 1, 'bad': 0})` ✓
- ☐ b. Ninguna de las opciones es correcta
- ☐ c. `df['class'] = df['class'].umap(('good': 1, 'bad': 0))`
- ☐ d. `df['class'] = df['class'].map({'good': 0, 'bad': 1})`

Respuesta correcta

Respuesta correcta:

```
df['class'] = df['class'].map({'good': 1, 'bad': 0})
```

La respuesta correcta es: **`df['class'] = df['class'].map({'good': 1, 'bad': 0})`**

Pregunta 18

[Marcar pregunta](#)**Incorrecta**

Se puntúa 0,00 sobre 2,00

Identificar y codificar las variables categóricas

Primero debes primero separar la variable objetivo que se encuentra almacenada en la columna **class**. Debes almacenarla en una nueva variable **y**. Eliminar la columna **class** del dataframe original.

Luego, con el dataframe resultante identificar las variables categóricas, y aplicar codificación one-hot-encoding a las variables identificadas. Recuerde que debe descartar las variables categóricas originales, y conservar las codificadas.

El número total de variables categóricas y el nuevo número de características en el dataframe es:

- ☐ a. 14 variables categóricas, 60 variables en total en el dataframe
- ☐ b. 14 variables categóricas, 48 variables en total en el dataframe
- ☐ c. 15 variables categóricas, 61 variables en total en el dataframe
- ☒ d. 14 variables categóricas, 61 variables en total en el dataframe ✖

Respuesta incorrecta.

Usar el siguiente código

```
y = df['class']
```

```
df = df.drop(columns=["class"])
```

```
categorical_cols = df.select_dtypes(include=['object', 'category']).columns  
print("Columnas categóricas:", categorical_cols)  
print("Total Columnas categóricas:", categorical_cols.size)
```

```
df_encoded = pd.get_dummies(df, columns=categorical_cols, drop_first=True)
# Mostrar las primeras filas del DataFrame codificado y las dimensiones resultantes
print("dimensiones del dataframe resultante: ", df_encoded.shape)
df_encoded.head(2)
```

La respuesta correcta es: **14 variables categóricas, 48 variables en total en el dataframe**

Pregunta 19

[Marcar pregunta](#)

Correcta

Se puntúa 2,00 sobre 2,00

División del Dataset en Conjuntos de Entrenamiento y Prueba

Se divide el dataset utilizando `train_test_split` para asegurar que el modelo se evalúe en datos no vistos. Para preservar la distribución de clases se utiliza el parámetro `stratify=y`.

- **Proporción:** 70% para entrenamiento y 30% para prueba.
- **Random State:** Se fija en 42 para reproducibilidad.

El número de registros de los conjuntos de entrenamiento y prueba respectivamente es:

☐ a. Ninguna de las opciones es correcta

☐ b.

Registros de X_train: 701
Registros de X_test: 310

☒ c.

Registros de X_train: 700
Registros de X_test: 300

 ✓

☐ d.

Registros de X_train: 48
Registros de X_test: 48

Respuesta correcta

Usar el siguiente código:

```
X = df_encoded

# Dividir el dataset en entrenamiento (70%) y prueba (30%) usando stratify para mantener la
distribución de clases
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.3,
    stratify=y,
    random_state=42
)

# Dimensiones de cada conjunto para verificar la división
print("Registros de X_train:", X_train.shape[0])
print("Registros de X_test:", X_test.shape[0])
```

La respuesta correcta es: Registros de X_train: 700
Registros de X_test: 300

Pregunta 20

[Marcar pregunta](#)**Incorrecta**

Se puntúa 0,00 sobre 2,00

Estandarización de los Predictores y entrenamiento de un modelo de regresión logística

La estandarización es esencial en modelos que utilizan regularización para garantizar que todas las variables se encuentren en la misma escala. Se utiliza `StandardScaler` para: _____

- Ajustar el escalador sobre el conjunto de entrenamiento.
- Transformar ambos conjuntos (entrenamiento y prueba).
- Entrenar un modelo de regresión logística con la siguiente configuración: **`LogisticRegression(penalty=None, max_iter=1000)`**

El intercepto (coeficiente θ_0) es:

☐ a. Ninguna de las opciones es correcta

☒ b.

Intercepto: -1.3071

✗

☐ c.

Intercepto: 2.3071

☐ d.

Intercepto: -1.7071

☐ e.

Intercepto: 1.3071

Respuesta incorrecta.

Usar el siguiente código:

```
# Instanciar el escalador
scaler = StandardScaler()

# Ajustar el escalador sobre el conjunto de entrenamiento y transformarlo
X_train_scaled = scaler.fit_transform(X_train)

# Transformar el conjunto de prueba utilizando el escalador ajustado
X_test_scaled = scaler.transform(X_test)

# Dimensiones de los datos escalados para verificar
print("Dimensiones de X_train_scaled:", X_train_scaled.shape)
print("Dimensiones de X_test_scaled:", X_test_scaled.shape)

# Entrenar el modelo
model = LogisticRegression(penalty=None, max_iter=1000)
model.fit(X_train_scaled, y_train)

print("Intercept: ", model.intercept_)
```

La respuesta correcta es:

Pregunta 21

[Marcar pregunta](#)**Incorrecta**

Se puntúa 0,00 sobre 2,00

Al evaluar el modelo con el conjunto de prueba, nos da como resultado la siguiente matriz de confusión, empleando la herramienta de sklearn: _____

Recuerde que el conjunto de prueba también se debe estandarizar!!

☐

a.

$$\begin{bmatrix} 44 & 46 \\ 33 & 177 \end{bmatrix}$$
☒

b.

$$\begin{bmatrix} 177 & 33 \\ 46 & 44 \end{bmatrix}$$

✗

Respuesta incorrecta.

Usar el siguiente código:

```
y_pred = model.predict(X_test_scaled)
```

```
# Calcular métricas de desempeño
accuracy = accuracy_score(y_test, y_pred)
conf_matrix = confusion_matrix(y_test, y_pred)
```

```
print(f"Accuracy: {accuracy}")
print("Confusion Matrix:")
print(conf_matrix)
```

La respuesta correcta es:

$$\begin{bmatrix} 44 & 46 \\ 33 & 177 \end{bmatrix}$$

Pregunta 22

[Marcar pregunta](#)**Incorrecta**

Se puntúa 0,00 sobre 2,00

Tener en cuenta las siguientes definiciones: _____

$$\text{Sensibilidad} = \frac{VP}{VP + FN}$$

$$\text{Especificidad} = \frac{VN}{VN + FP}$$

Para el conjunto de prueba, las métricas de sensibilidad y especificidad son respectivamente (puede redondear al valor más cercano):

☐ a.

La sensibilidad es: 74.28% y la especificidad es: 48.28%

☐ b.

La sensibilidad es: 84.28% y la especificidad es: 84.28%

☐ c. Ninguna de las opciones es correcta

☐ d.

La sensibilidad es: 84.28% y la especificidad es: 48.88%

☒ e.

La sensibilidad es: 48.88% y la especificidad es: 84.28%

✗

Respuesta incorrecta.

Puedes usar `classification_report` y puedes identificar que la sensibilidad es el recall

para la clase positiva y la especificidad es el recall para la clase negativa:

```
class_report = classification_report(y_test, y_pred)
```

```
print("Classification Report:")
```

```
print(class_report)
```

```
Classification Report:
```

```
precision    recall
```

```
0          0.57          0.49
```

```
1          0.79          0.84
```

La respuesta correcta es: La sensibilidad es: 84.28% y la especificidad es: 48.88%

Pregunta 23

[Marcar pregunta](#)**Incorrecta**

Se puntúa 0,00 sobre 2,00

Ajuste de Modelos de Regresión Logística con Regularización

Se ajusta un modelo de regresión logística usando lasso: _____

- **L1 (Lasso):** Utiliza `penalty='l1'` y un solver compatible (`liblinear`), utiliza **C=1**

Después de ajustar el modelo, el número de variables que se pueden descartar es:

- ☐ a. En total se pueden descartar 10 (diez) variables, pues su coeficiente es 0.
- ☐ b. No se pueden descartar variables, no hay suficiente información
- ☐ c. Se pueden descartar variables, pero no es posible determinar cuantas.
- ☐ d. En total se pueden descartar 3 (tres) variables, pues su coeficiente es 0.
- ☒ e. En total se pueden descartar 4 (cuatro) variables, pues su coeficiente es 0. **×**

Respuesta incorrecta.

Puedes usar el siguiente código:

```
l1_model = LogisticRegression(penalty='l1', solver='liblinear', max_iter=1000, C=1)
# Entrenar el modelo
l1_model.fit(X_train_scaled, y_train)
print("Total de variables con coeficiente 0: ", (l1_model.coef_==0).sum())
```

La respuesta correcta es:

En total se pueden descartar 3 (tres) variables, pues su coeficiente es 0.

Pregunta 24

[Marcar pregunta](#)**Incorrecta**

Se puntúa 0,00 sobre 2,00

Ajuste de Modelos de Regresión Logística con Regularización

Se ajusta un modelo de regresión logística usando Ridge: _____

- **L2 (Ridge):** Utiliza `penalty='l1'` y un solver compatible (`lbfgs`). Usar `C=0.1`

Debes ajustar el modelo y comparar el recall para los tres modelos entrenados. Los resultados son los siguientes:

Usa `recall_score` para realizar el reporte:

from sklearn.metrics import recall_score

☐ a.

No penalty=0.838
L1(lasso)=0.838
L2(Ridge)=0.862

☐ b.

No penalty=0.862
L1(lasso)=0.889
L2(Ridge)=0.852

☒ c.

No penalty=0.842
L1(lasso)=0.842
L2(Ridge)=0.842

 ✖

☐ d.

No penalty=0.842
L1(lasso)=0.838
L2(Ridge)=0.852

Respuesta incorrecta.

Usar el siguiente código:

```
# El solver 'lbfgs' es el predeterminado y es compatible con L2
l2_model = LogisticRegression(penalty='l2', solver='lbfgs', max_iter=1000, C=0.1)
l2_model.fit(X_train_scaled, y_train)

#comparar los tres modelos:
y_pred = model.predict(X_test_scaled)
no_penalty=recall_score(y_test, y_pred)

y_pred = l1_model.predict(X_test_scaled)
l1_penalty=recall_score(y_test, y_pred)

y_pred = l2_model.predict(X_test_scaled)
l2_penalty=recall_score(y_test, y_pred)

print(f"Recall para cada modelo:\nNo penalty={no_penalty}\nL1(lasso)={l1_penalty}\nL2(Ridge)=
{l2_penalty}")
```

```
Recall para cada modelo:
No penalty=0.8428571428571429
L1(lasso)=0.8380952380952381
L2(Ridge)=0.8523809523809524
```

La respuesta correcta es:

```
No penalty=0.842
L1(lasso)=0.838
L2(Ridge)=0.852
```

[Finalizar revisión](#)