



Comenzado el

lunes, 1 de septiembre de 2025, 22:07

Estado

Finalizado

Finalizado en

lunes, 1 de septiembre de 2025, 22:21

Tiempo empleado

13 minutos 45 segundos

Puntos

20,00/21,00

Calificación

4,76 de 5,00 (95,24%)

Pregunta 1

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Un científico de datos entrena un modelo de regresión lineal para predecir el precio de las viviendas. El modelo logra un R^2 de 0.98 en los datos de entrenamiento, pero solo 0.65 en los datos de prueba. Los coeficientes (parámetros θ) del modelo para algunas variables son extremadamente grandes. _____

¿Cuál es el diagnóstico más probable del problema y la solución más adecuada?

- ☐ a. La tasa de aprendizaje es muy baja. La solución es reentrenar el modelo con un optimizador diferente, como Adam.
- ☒ b. El modelo sufre de alta varianza (overfitting). La solución es introducir un término de regularización (L1 o L2) a la función de costo. ✓
- ☐ c. El problema es la multicolinealidad. La única solución es eliminar manualmente las variables correlacionadas.
- ☐ d. El modelo sufre de alto sesgo (underfitting). La solución es usar menos características o aumentar la regularización.

Respuesta correcta

La gran diferencia de rendimiento entre entrenamiento y prueba es un síntoma clásico de overfitting. La regularización penaliza la complejidad del modelo (coeficientes grandes) para mejorar su capacidad de generalización. La solución es introducir un término de regularización (L1 o L2) a la función de costo.

La respuesta correcta es:

El modelo sufre de alta varianza (overfitting). La solución es introducir un término de regularización (L1 o L2) a la función de costo.

Pregunta 2

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

La regularización Elastic Net combina las penalizaciones L1 y L2.

¿En qué escenario industrial esta técnica sería particularmente superior tanto a Lasso como a Ridge por separado? _____

- ☐ a. Cuando el objetivo principal es la interpretabilidad del modelo y se necesita que la mayoría de los coeficientes sean exactamente cero.
- ☐ b. En un problema con pocas características y sin correlación entre ellas.
- ☐ c. Cuando el tiempo de entrenamiento del modelo es la principal restricción.
- ☒ d. En un análisis genómico donde hay miles de genes (características), y se sabe que muchos de ellos operan en grupos correlacionados. ✓

Respuesta correcta

En un análisis genómico donde hay miles de genes (características), y se sabe que muchos de ellos operan en grupos correlacionados.:

Este es el caso de uso ideal para Elastic Net. El componente L1 (Lasso) realiza selección de características para manejar la alta dimensionalidad, y el componente L2 (Ridge) maneja la multicolinealidad, animando al modelo a seleccionar o descartar los grupos de genes correlacionados juntos.

La respuesta correcta es:

En un análisis genómico donde hay miles de genes (características), y se sabe que muchos de ellos operan en grupos correlacionados.

Pregunta 3

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

La métrica F1-Score se define como la media armónica de la Precisión y la Sensibilidad. ¿Cuál es la principal ventaja de usar la media armónica en lugar de una media aritmética simple?

- ☐ a. La media armónica es más fácil de calcular computacionalmente.
- ☐ b. La media armónica es la única forma de combinar dos métricas que están en diferentes escalas.
- ☒ c. La media armónica penaliza fuertemente los valores extremos. Para obtener un F1-Score alto, tanto la Precisión como la Sensibilidad deben ser altas. ✓
- ☐ d. La media armónica siempre da un valor más alto que la media aritmética, lo que ayuda a que los modelos parezcan mejores.

Respuesta correcta

A diferencia de la media aritmética, la media armónica se ve arrastrada hacia el valor más bajo. Por ejemplo, si Precisión=1.0 y Sensibilidad=0.1, la media aritmética es 0.55, pero el F1-Score es solo ≈ 0.18 . Esto asegura que el F1-Score solo sea alto si ambas métricas son balanceadas y altas.

La respuesta correcta es:

La media armónica penaliza fuertemente los valores extremos. Para obtener un F1-Score alto, tanto la Precisión como la Sensibilidad deben ser altas.

Pregunta 4

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Un colega te muestra el resultado de un `classification\_report` de scikit-learn para un problema de detección de spam ('spam' es la clase positiva).

¿Qué conclusión puedes sacar sobre el rendimiento del modelo a partir de este reporte? _____

```

precision  recall  f1-score  support

ham       0.99    0.97    0.98     900
spam      0.78    0.92    0.84     100

accuracy                0.96    1000
macro avg    0.88    0.94    0.91    1000
weighted avg 0.97    0.96    0.96    1000

```

- ☐ a. El modelo es muy bueno identificando correos que son spam, pero es demasiado agresivo y marca muchos correos legítimos (ham) como spam.
- ☐ b. El modelo es casi perfecto, como lo demuestra la exactitud del 96% y el F1-score de 'ham' de 0.98.
- ☐ c. El modelo es excelente para no marcar correos legítimos (ham) como spam, pero a costa de no detectar una cantidad significativa de correos que sí son spam.
- ☒ d. El modelo logra encontrar a la mayoría de los correos spam (alto recall), pero un número considerable de sus predicciones de 'spam' son incorrectas (precisión moderada). ✓

Respuesta correcta

El `recall` de 0.92 para 'spam' indica que el modelo captura el 92% de todos los correos spam existentes. Sin embargo, la `precision` de 0.78 indica que cuando el modelo etiqueta un correo como 'spam' solo es correcto el 78% de las veces, lo que

El modelo etiqueta un correo como spam, solo acierta el 78% de las veces, lo que significa que el 22% de esas alertas son falsos positivos.

La respuesta correcta es:

El modelo logra encontrar a la mayoría de los correos spam (alto recall), pero un número considerable de sus predicciones de 'spam' son incorrectas (precisión moderada).

Pregunta 5

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Generalmente, el término de intercepción o sesgo (θ_0) no se incluye en el término de penalización de la regularización. ¿Cuál es la razón teórica fundamental para esta exclusión?

- ☐ a. Porque penalizar el intercepto haría que el modelo fuera invariante a la escala de la variable objetivo, lo cual no es deseable.
- ☐ b. Por razones computacionales, incluir θ_0 en la suma de la penalización hace que el problema de optimización sea no convexo.
- ☐ c. Porque θ_0 siempre es cero y no necesita ser regularizado.
- ☒ d. Porque el intercepto θ_0 captura la media base de la variable objetivo, y penalizarlo significaría forzar a que la predicción promedio sea cero, lo cual no tiene sentido. ✓

Respuesta correcta

La regularización busca reducir la influencia de las características (es decir, la pendiente de la relación, representada por θ_j). El intercepto simplemente 'posiciona' la línea o el hiperplano. Forzarlo hacia cero no tiene que ver con la complejidad del modelo, sino con forzar a que la predicción base sea cero, lo que raramente es el caso.

La respuesta correcta es: Porque el intercepto θ_0 captura la media base de la variable objetivo, y penalizarlo significaría forzar a que la predicción promedio sea cero, lo cual no tiene sentido.

Pregunta 6

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Un banco utiliza un modelo para predecir si una solicitud de préstamo será '**aprobada**' o '**rechazada**'. La métrica de **Precisión** para la clase '**aprobada**' es **0.90**. ¿Cuál es la interpretación de negocio correcta de este número?

- ☐ a. El 90% de todos los solicitantes que deberían haber sido aprobados, fueron aprobados por el modelo.
- ☐ b. El 90% de los préstamos malos son rechazados correctamente por el modelo.
- ☐ c. El modelo aprueba correctamente al 90% del total de solicitantes.
- ☒ d. De todas las solicitudes de préstamo que el modelo aprobó, el 90% fueron decisiones correctas (es decir, solicitantes que realmente merecían la aprobación). ✓

Respuesta correcta

La precisión mide la fiabilidad de las predicciones positivas. Un valor de 0.90 significa que 9 de cada 10 préstamos que el modelo aprueba son, de hecho, buenos préstamos, minimizando el riesgo de aprobar a quien no se debe (falsos positivos).

La respuesta correcta es:

De todas las solicitudes de préstamo que el modelo aprobó, el 90% fueron decisiones correctas (es decir, solicitantes que realmente merecían la aprobación).

Pregunta 7

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Para que la regularización funcione de manera efectiva, un pre-procesamiento de los datos es crucial. ¿Cuál de los siguientes pasos es el más importante antes de aplicar un modelo de regresión lineal con regularización L1 o L2? _____

- ☐ a. Asegurarse de que no haya valores nulos en el conjunto de datos
- ☐ b. Eliminar todos los valores atípicos (outliers) del conjunto de datos.
- ☐ c. Convertir todas las variables categóricas a numéricas usando one-hot encoding.
- ☒ d. Estandarizar o normalizar las características numéricas para que tengan una escala similar. ✓

Respuesta correcta

La regularización penaliza la magnitud de los coeficientes. Si una característica tiene una escala mucho mayor que otra (ej. salario en miles vs. años de experiencia), su coeficiente será naturalmente más pequeño, y la penalización lo afectará de manera injusta. Estandarizar asegura que la penalización se aplique de forma equitativa a todas las características.

La respuesta correcta es:

Estandarizar o normalizar las características numéricas para que tengan una escala similar.

Pregunta 8

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Estás construyendo un modelo de regresión logística para predecir el riesgo crediticio de un cliente. Tu conjunto de datos tiene más de 300 características, y sospechas que muchas de ellas son irrelevantes. Tu objetivo es crear un modelo final que sea más simple e interpretable. _____

¿Qué técnica de regularización es la más apropiada?

- ☐ a. Validación cruzada, porque permite encontrar los mejores hiperparámetros del modelo.
- ☒ b. Regularización Lasso (L1), porque tiene la propiedad de reducir los coeficientes de las características menos importantes a exactamente cero. ✓
- ☐ c. Regularización Ridge (L2), porque distribuye la penalización entre todas las características de manera uniforme.
- ☐ d. Eliminación aleatoria de características con baja correlación, porque reduce la dimensionalidad del dataset.

Respuesta correcta

La penalización L1 es ideal para la selección de características (feature selection), ya que elimina efectivamente las variables irrelevantes del modelo, resultando en una solución más simple.

La respuesta correcta es:

Regularización Lasso (L1), porque tiene la propiedad de reducir los coeficientes de las características menos importantes a exactamente cero.

Pregunta 9

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

En un problema de clasificación de imágenes para detectar si una foto contiene un '**gato**' (clase 1) o '**no gato**' (clase 0), un modelo produce la siguiente matriz de confusión en un set de prueba de 1000 imágenes: $[[TN=850, FP=20], [FN=30, TP=100]]$. _____

¿Qué métrica describe mejor la capacidad del modelo para identificar correctamente a todos los gatos que realmente están presentes en el set de prueba?

- ☐ a. La Precisión (Precision), que es $\approx 83.3\%$
- ☒ b. La Sensibilidad (Recall), que es $\approx 76.9\%$ ✓
- ☐ c. La Especificidad (Specificity), que es $\approx 97.7\%$
- ☐ d. La Exactitud (Accuracy), que es $\approx 95\%$

Respuesta correcta

El Recall (o Sensibilidad) responde a la pregunta: 'De todos los gatos que realmente había, ¿qué porcentaje logró encontrar el modelo?'. Se enfoca en minimizar los falsos negativos (FN).

La respuesta correcta es: **La Sensibilidad (Recall), que es $\approx 76.9\%$**

Pregunta 10

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Trabajas para una plataforma de streaming de video y diseñas un modelo de clasificación para identificar contenido inapropiado para niños. El costo de un ****falso negativo**** (no detectar un video inapropiado) es extremadamente alto. Por otro lado, un ****falso positivo**** (marcar un video seguro como inapropiado) es un inconveniente menor. _____

¿Qué métrica deberías priorizar al optimizar tu modelo?

- ☐ a. Exactitud (Accuracy), ya que proporciona la mejor medida del rendimiento general del modelo.
- ☒ b. Sensibilidad (Recall), para minimizar la cantidad de videos inapropiados que el modelo no detecta. ✓
- ☐ c. Especificidad, para identificar correctamente la mayor cantidad de contenido seguro.
- ☐ d. Precisión, para asegurar que cuando el modelo marca un video como inapropiado, esté muy seguro de su decisión.

Respuesta correcta

Maximizar el Recall ($TP/(TP+FN)$) es equivalente a minimizar los falsos negativos (FN). En este escenario, es crucial encontrar la mayor cantidad posible de contenido inapropiado, incluso si eso significa marcar incorrectamente algunos videos seguros.

La respuesta correcta es:

Sensibilidad (Recall), para minimizar la cantidad de videos inapropiados que el modelo no detecta.

Pregunta 11

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Un conjunto de datos sobre fraudes de tarjetas de crédito contiene un **99.8%** de transacciones no fraudulentas y un **0.2%** de transacciones fraudulentas. Un modelo de clasificación logra una exactitud (accuracy) del **99.8%**.

¿Por qué esta métrica es una mala elección para evaluar el modelo en este contexto?

- ☒ a. Porque el modelo podría estar simplemente clasificando todas las transacciones como **'no fraudulentas'** y aun así alcanzar esa exactitud. ✓
- ☐ b. Porque la exactitud no toma en cuenta los verdaderos negativos (TN).
- ☐ c. Porque la exactitud no es una métrica válida para problemas de clasificación binaria.
- ☐ d. Porque una exactitud del 99.8% es demasiado alta para ser realista, lo que indica un error en los datos.
- ☐ e. Ninguna de las opciones es correcta.

Respuesta correcta

Este es el problema de la **'paradoja de la exactitud'**. En un dataset tan desbalanceado, un modelo trivial que siempre predice la clase mayoritaria puede parecer muy preciso, pero es completamente inútil para detectar la clase minoritaria de interés (fraude).

La respuesta correcta es:

Porque el modelo podría estar simplemente clasificando todas las transacciones como 'no fraudulentas' y aun así alcanzar esa exactitud.

Pregunta 12

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

Estás trabajando con un dataset que tiene dos características, '**Experiencia**' e '**Historial_Crediticio**', que están altamente correlacionadas (multicolinealidad). Si aplicas Regresión Lasso (L1), ¿cuál es el comportamiento más probable que observarás en los coeficientes θ_j de estas dos variables?

- ☒ a. Lasso tenderá a seleccionar una de las variables (asignándole un coeficiente no nulo) y a eliminar la otra (asignándole un coeficiente de cero). ✓
- ☐ b. Ambos coeficientes serán grandes para reflejar su importancia conjunta.
- ☐ c. El modelo no convergerá debido a la multicolinealidad.
- ☐ d. Lasso asignará un coeficiente pequeño pero no nulo a ambas variables.

Respuesta correcta

Debido a la naturaleza de la penalización L1, cuando hay un grupo de características correlacionadas, Lasso tiende a elegir arbitrariamente una de ellas y encoger las demás a cero. Este comportamiento puede ser inestable.

La respuesta correcta es:

Lasso tenderá a seleccionar una de las variables (asignándole un coeficiente no nulo) y a eliminar la otra (asignándole un coeficiente de cero).

Pregunta 13

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

La función de costo para un modelo lineal regularizado es

$$J(\theta) = \text{Error}(\theta) + \text{Penalización}(\theta)$$

Si decides no aplicar ninguna regularización, ¿a qué equivale esto en términos del hiperparámetro λ ?

Equivale a establecer

☐ a. $\lambda = -1$

Equivale a establecer

☐ b. $\lambda = 1$

☐ c. Ninguna de las opciones es correcta

Equivale a establecer

☒ d. $\lambda = 0$ ✓

La ausencia de regularización no se puede representar con el valor de

☐ e. λ

Respuesta correcta

Si $\lambda = 0$ el término de penalización se anula:

$$0 \times \sum \theta_j^2 = 0$$

y la función de costo se reduce a su forma no regularizada, optimizando únicamente el error de predicción.

La respuesta correcta es:
Equivale a establecer $\lambda = 0$

Pregunta 14

[Marcar pregunta](#)**Incorrecta**

Se puntúa 0,00 sobre 1,00

Un analista ajusta el umbral de decisión (**threshold**) de un modelo de regresión logística. Originalmente, cualquier predicción con **probabilidad** > 0.5 se clasificaba como '**positiva**'. Ahora, lo cambia a > 0.8 . ¿Cuál es el efecto más probable sobre la Precisión y la Sensibilidad (Recall) del modelo?_____

- ☐ a. La Precisión probablemente aumentará, y la Sensibilidad probablemente disminuirá.
- ☒ b. La Precisión probablemente disminuirá, y la Sensibilidad probablemente aumentará. ✖
- ☐ c. Tanto la Precisión como la Sensibilidad aumentarán.
- ☐ d. No habrá ningún cambio en la Precisión ni en la Sensibilidad.

Respuesta incorrecta.

Al ser más '**exigente**' para clasificar como positivo (umbral más alto), el modelo cometerá menos falsos positivos (aumentando la precisión), pero a costa de no detectar más casos positivos reales (aumentando los falsos negativos y, por tanto, disminuyendo la sensibilidad).

La respuesta correcta es:

La Precisión probablemente aumentará, y la Sensibilidad probablemente disminuirá.

Pregunta 15

[Marcar pregunta](#)

Correcta

Se puntúa 1,00 sobre 1,00

La función de costo para la Regresión Ridge se define como: _____

$$J(\theta) = MSE(\theta) + \lambda \sum_{j=1}^n \theta_j^2$$

Un colega te pregunta qué sucede si el hiperparámetro de regularización λ se establece en un valor extremadamente grande (ej. $\lambda \rightarrow \infty$). ¿Cuál sería el efecto en los parámetros del modelo $(\theta_1, \theta_2, \dots, \theta_n)$?

- ☐ a. Los parámetros θ_j crecerían sin límite para compensar la fuerte penalización.
- ☐ b. Exactamente la mitad de los parámetros se volverían cero, y la otra mitad crecería.
- ☐ c. No tendría ningún efecto; el modelo convergería a la solución de Mínimos Cuadrados Ordinarios.
- ☒ d. Todos los parámetros θ_j (excepto el intercepto θ_0) tenderían a cero, resultando en un modelo que predice la media del valor objetivo. ✓

Respuesta correcta

Para minimizar una función de costo dominada por el término

$$\lambda \sum_{j=1}^n \theta_j^2$$

el optimizador forzará a que todos los θ_j sean lo más cercanos a cero posible. Un modelo donde todos los coeficientes de las características son cero simplemente predice el valor promedio de la variable dependiente (intercepto).

La respuesta correcta es:

Todos los parámetros θ_j (excepto el intercepto θ_0) tenderían a cero, resultando en un modelo que predice la media del valor objetivo.

Información

[Marcar pregunta](#)

Las siguientes preguntas se deben responder usando el siguiente archivo: [enlace_archivo](#)

El archivo contiene dos columnas:

y_real	y_pred_prob
---------------	--------------------

y_real: es la etiqueta real, es decir, la respuesta correcta.

y_pred_prob: es la probabilidad que predice el modelo.

Pregunta 16

[Marcar pregunta](#)**Correcta**

Se puntúa 2,00 sobre 2,00

El número de instancias por cada clase es:

- ☐ a.

Clase 1:	7779
Clase 0:	7779
- ☐ b.

Clase 1:	7789
Clase 0:	7789
- ☒ c.

Clase 1:	7879
Clase 0:	7879

 ✓
- ☐ d.

Clase 1:	7897
Clase 0:	7897

Respuesta correcta

Usa el siguiente código:

```
import pandas as pd
df = pd.read_csv("practica_Q3.csv")
df["y_real"].value_counts()
```

La respuesta correcta es:

Clase 1:	7879
Clase 0:	7879

Pregunta 17

[Marcar pregunta](#)**Correcta**

Se puntúa 2,00 sobre 2,00

Debe emplear un umbral de decisión de 0.5, las respectivas métricas son las siguientes:

- Accuracy: 62.58
- ☐ a. Precision: 63.55
Recall: 54.30
- Accuracy: 61.58
- ☐ b. Precision: 64.55
Recall: 54.30
- Accuracy: 61.58
- ☒ c. Precision: 63.55 ✓
Recall: 54.30
- Accuracy: 61.58
- ☐ d. Precision: 63.55
Recall: 55.30

Respuesta correcta

Usar el siguiente código:

```
from sklearn.metrics import confusion_matrix
from sklearn.metrics import precision_score
from sklearn.metrics import recall_score
from sklearn.metrics import accuracy_score
import pandas as pd

df = pd.read_csv("practica_Q3.csv")
y_pred = (df.y_pred_prob >= 0.5).astype('int')
y_real = df.y_real
print("Accuracy: ", accuracy_score(y_real, y_pred)*100)
print("Precision: ", precision_score(y_real, y_pred)*100)
print("Recall: ", recall_score(y_real, y_pred)*100)
```

La respuesta correcta es: **Accuracy: 61.58 Precision: 63.55 Recall: 54.30**

Pregunta 18

[Marcar pregunta](#)**Correcta**

Se puntúa 2,00 sobre 2,00

La matriz de confusión es la siguiente:

- ☐ a. $\begin{bmatrix} 4279, 3600 \\ 2454, 5425 \end{bmatrix}$
- ☐ b. $\begin{bmatrix} 4279, 2454 \\ 3600, 5425 \end{bmatrix}$
- ☐ c. $\begin{bmatrix} 4279, 3600 \\ 2454, 5479 \end{bmatrix}$
- ☒ d. $\begin{bmatrix} 5425, 2454 \\ 3600, 4279 \end{bmatrix}$ ✓

Respuesta correcta

Usar el siguiente código:

```
from sklearn.metrics import confusion_matrix
```

```
# [TN,FP],[FN,TP]  
confusion_matrix(y_real, y_pred)
```

La respuesta correcta es: $\begin{bmatrix} 5425, 2454 \\ 3600, 4279 \end{bmatrix}$

[Finalizar revisión](#)