



¿Qué es el algoritmo de k vecinos más cercanos (KNN)?



K-Nearest Neighbors (KNN): Aprendiendo de la Vecindad

Un algoritmo intuitivo basado en la similitud






La Intuición Principal

Dime con quién andas y te diré quién eres

- Si sus 3 vecinos más próximos son deportistas, es muy probable que él también lo sea.
- Si la mayoría son artistas, probablemente él también comparta ese interés.




¿Cómo Funciona KNN para Clasificación?




La Clave está en "K"

¿Cómo Funciona KNN para Clasificación?




vecindario



¿Cómo Funciona KNN para Clasificación?

Dado un nuevo punto de datos que queremos clasificar, el algoritmo sigue estos pasos:

- 1.Elegir el número K:** Se selecciona un número de vecinos (hiperparámetro K).
- 2.Calcular la Distancia:** Se calcula la distancia entre el nuevo punto y **todos** los puntos del conjunto de entrenamiento.
- 3.Ordenar los Vecinos:** Se ordenan los puntos de entrenamiento del más cercano al más lejano.
- 4.Seleccionar los K-Vecinos:** Se eligen los primeros K puntos de la lista ordenada.
- 5.Realizar una Votación:** Se observa la etiqueta de clase de estos K vecinos. La clase que más se repite (la **moda**) se asigna al nuevo punto de datos.




¿Cómo Calculamos la Distancia o Similitud?

Intuición Básica:



- Para predecir el valor de una nueva instancia x , se buscan los **K ejemplos más cercanos** en el conjunto de entrenamiento.
- La **predicción** se basa en los **valores de estos vecinos** (votación para clasificación o promedio para regresión).

Concepto de Cercanía o Similitud



¿Cómo Calculamos la Distancia o Similitud?



Esta es una de las más utilizadas:



- No es invariante en la escala, normalice los datos antes de usar esta medida de distancia.
- Apropiaada en espacios de baja dimensionalidad.

¿Cómo Calculamos la Distancia o Similitud?

Manhatta




Fórmula general:

$$P = (p_1, p_2, p_3, \dots, p_n)$$

$$Q = (q_1, q_2, q_3, \dots, q_n)$$



$$d_{\text{Manhattan}}(P, Q) = \sum_{i=1}^n |p_i - q_i|$$

¿Hay otras formas?





Ejemplo

Regresión: suponga que tiene los siguientes datos y quiere estimar un modelo de regresión basado en KNN







Ejemplo

Regresión: suponga que tiene los siguientes datos y quiere estimar un modelo de regresión basado en KNN



Ejemplo



Bias y Variance

El Rol de K : Balance entre Bias y Variance

Sesgo (Bias):

Error introducido por **simplificar demasiado** el modelo.

Varianza (Variance):



Error debido a la **sensibilidad del modelo** a pequeñas fluctuaciones en los datos.

K pequeño (por ejemplo, $k=1$) → Muy **flexible**,

bajo bias → El modelo **se adapta demasiado a los datos** (overfitting).

K grande (por ejemplo, $k=30$) → Modelo **menos flexible**,


baja varianza, pero puede **no captar la complejidad** de los datos (underfitting).



Ejemplo

Cada instancia tiene una región de influencia

En la figura tenemos una Ilustración de la frontera de decisión del vecino más cercano como la unión de los poliedros de los ejemplos de entrenamiento que pertenecen a la misma clase.




La decisión se toma por votación:

A
y: ● ● ● ● ■ ■ ■ ■ ■ ■ ■ ■





Majority vote: ■
Plurality vote: ■

B
y: ● ● ● ■ ■ ■ ◆ ◆ ◆ ◆ ◆ ◆ ◆ ◆

Majority vote: None
Plurality vote: ◆




Ejemplo



Ventajas

KNN es...

- Simple (sencillo de aplicar e interpretar).
- Polivalente (puede ser utilizado para la clasificación o la regresión).
- No paramétrico (no hace suposiciones explícitas sobre la forma funcional de los datos, evitando los peligros de la distribución subyacente de los datos).
- Ajustable de manera automática a medida que surgen cambios en la distribución de los datos, ya que este se basa en instancias.



Desventajas

KNN es...

- Computacionalmente costoso. Ocupa gran cantidad de memoria y almacenamiento de datos.
- Sensible a los valores atípicos. La precisión y rendimiento se ven afectados por el ruido y las características irrelevantes.
- Propenso al sobreajuste (overfitting)
- Sufre de la maldición de la dimensionalidad.
- Muy sensible a la unidad de medida de los atributos (se deben normalizar las variables).

