

Regresión logística

UNIDAD 2: APRENDIZAJE SUPERVISADO



Agenda

01

Acercamiento intuitivo

¿Qué es y en qué consiste el algoritmo de regresión logística?

02

Descripción matemática

03

Aplicación Real

Diagnóstico de la diabetes en la población de nativos americanos Pima

04

Consideraciones finales

Ventajas y desventajas del algoritmo

05

Lecturas complementarias

06

Práctica en Google Colab

07

¡Comprueba tu conocimiento!


01

Acercamiento intuitivo

- ¿Qué es el algoritmo de regresión logística?
- ¿En qué consiste su implementación? (pasos)

¿Qué es la regresión logística?

La **regresión logística** es una técnica de **análisis de datos** que utiliza las matemáticas para encontrar las **relaciones entre dos factores de datos**. Luego, utiliza esta relación para predecir el valor de uno de esos factores basándose en el otro. Normalmente, **la predicción tiene un número finito de resultados**, como un sí o un no.



Fuente: cienciadedatos.net

¿Por qué es importante la regresión logística?

1

Simplicidad

2

Velocidad

3

Flexibilidad

4

Visibilidad

Tipos de regresión logística

Regresión logística binaria: la variable objetivo tiene solo dos resultados posibles, como Spam o No Spam.



Regresión logística multi-clase: la variable objetivo tiene tres o más categorías nominales, como predecir el tipo de vino.
calificación de un restaurante o de un producto de 1 a 5.



Metricas que se utilizan

1

Accuracy

2

Recall

3

Specificity

4

Precision

5


Matriz de confusión

6

Área bajo la curva ROC


Regresión lineal vs. Regresión logística

La **regresión lineal** le brinda una **salida continua**, pero la **regresión logística** proporciona una **salida constante**. Un ejemplo de la salida continua es el precio de la vivienda y el precio de las acciones. El ejemplo de la salida discreta es predecir si un paciente tiene cáncer o no, predecir si el cliente abandonará.




Fuente: datacamp.com

Aplicaciones de la regresión logística



Sanidad



Fabricación



Finanzas



Marketing

¿En qué consiste su implementación?

1

Cargar los datos

2

Seleccionar característica

3

División de datos

4

Desarrollo y predicción del modelo

5

Evaluación del modelo utilizando la matriz de confusión y sus metricas

6

Curva ROC

02

Descripción matemática

Para encontrar la ecuación de la **regresión logística**, se debe empezar por la ecuación de la **regresión lineal**.



Ecuación de regresión lineal

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1$$


$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x,$$

Función sigmoide

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}},$$

$$g(z) = \frac{1}{1 + e^{-z}}$$

La **función sigmoide** es fundamental en la regresión logística porque se utiliza para transformar la salida de la regresión lineal en una probabilidad.



Aplicando la **función sigmoidea en la regresión lineal**, se obtien lo siguiente:

Ecuación general de la regresión logistica

$$\begin{aligned} P(y = 1 \mid x; \theta) &= h_{\theta}(x) \\ P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x) \end{aligned}$$

$$p(y \mid x; \theta) = (h_{\theta}(x))^y (1 - h_{\theta}(x))^{1-y}$$

Donde **$P(\mathbf{y})$** es la probabilidad de que ocurra **$\mathbf{y}$**

Se define la siguiente función de costo

$$\begin{aligned} L(\theta) &= p(\vec{y} \mid X; \theta) \\ &= \prod_{i=1}^m p(y^{(i)} \mid x^{(i)}; \theta) \\ &= \prod_{i=1}^m (h_{\theta}(x^{(i)}))^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}} \end{aligned}$$

$$\begin{aligned} \ell(\theta) &= \log L(\theta) \\ &= \sum_{i=1}^m y^{(i)} \log h(x^{(i)}) + (1 - y^{(i)}) \log(1 - h(x^{(i)})) \end{aligned}$$

Optimización usando el algoritmo de gradiente descendiente

$$\begin{aligned}
 g'(z) &= \frac{d}{dz} \frac{1}{1 + e^{-z}} \\
 &= \frac{1}{(1 + e^{-z})^2} (e^{-z}) \\
 &= \frac{1}{(1 + e^{-z})} \cdot \left(1 - \frac{1}{(1 + e^{-z})}\right) \\
 &= g(z)(1 - g(z)).
 \end{aligned}$$

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{\partial}{\partial \theta_j} \left(-\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(g(z^{(i)})) + (1 - y^{(i)}) \log(1 - g(z^{(i)})) \right] \right)$$

$$\frac{\partial J(\theta)}{\partial \theta_j} = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \frac{\partial}{\partial \theta_j} \log(g(z^{(i)})) + (1 - y^{(i)}) \frac{\partial}{\partial \theta_j} \log(1 - g(z^{(i)})) \right]$$

$$\frac{\partial \log(g(z^{(i)}))}{\partial \theta_j} = \frac{1}{g(z^{(i)})} \cdot \frac{\partial g(z^{(i)})}{\partial \theta_j}$$

$$\frac{\partial g(z^{(i)})}{\partial \theta_j} = g(z^{(i)}) \cdot (1 - g(z^{(i)})) \cdot x_j^{(i)}$$

$$\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} \sum_{i=1}^m \left(g(z^{(i)}) - y^{(i)} \right) \cdot x_j^{(i)}$$

$$\theta_j := \theta_j - \alpha \cdot \frac{\partial J(\theta)}{\partial \theta_j}$$

Optimización usando el algoritmo de gradiente descendiente

Batch gradient descent

$$\theta_j := \theta_j + \alpha \sum_{i=1}^m (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)} \quad (\text{for every } j).$$

Online gradient descent

Loop {

for i=1 to m, {

$$\theta_j := \theta_j + \alpha (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)} \quad (\text{for every } j).$$

}

}

Propiedades clave de la ecuación de regresión logística

1

La **variable dependiente** de la regresión logística obedece a la "distribución de Bernoulli".

2

La estimación/predicción se basa en la '**máxima verosimilitud**'.

3

La regresión logística no evalúa el **coeficiente de determinación R^2**

03

Aplicación Real

Dataset sobre la diabetes en la población de nativos americanos Pima, ¿Cuál es el resultado de aplicar regresión logística en este caso?

Pima Indians Diabetes Database


Como científico de datos, usted tiene como objetivo principal predecir si un paciente tiene diabetes en función de las características médicas proporcionadas.

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1

Fuente: Grafica sacada con la ayuda de Jupyter Notebook


Distribución de la variable target

Distribución del número de ejemplos de cada clase en el conjunto de datos



Fuente: Grafica sacada con la ayuda de Jupyter Notebook

Distribución de las variables de entrada




Fuente: Grafica sacada con la ayuda de Jupyter Notebook

Aplicación del algoritmo regresión logística

Conjunto de entrenamiento

No Skill: ROC AUC=0.5000
Logistic: ROC AUC=0.7968



Fuente: Grafica sacada con la ayuda de Jupyter Notebook

Metricas


	precision	recall	f1-score	support
Sin diabetes	0.77	0.89	0.83	403
Con diabetes	0.70	0.49	0.58	211
accuracy			0.75	614
macro avg	0.73	0.69	0.70	614
weighted avg	0.75	0.75	0.74	614

Metricas

	precision	recall	f1-score	support
Sin diabetes	0.77	0.81	0.79	97
Con diabetes	0.65	0.60	0.62	57
accuracy			0.73	154
macro avg	0.71	0.71	0.71	154
weighted avg	0.73	0.73	0.73	154

Conjunto de prueba

No Skill: ROC AUC=0.5000
Logistic: ROC AUC=0.7905



Fuente: Grafica sacada con la ayuda de Jupyter Notebook

04

Consideraciones finales

- Ventajas y desventajas de la regresión logística

Ventajas



- Debido a su naturaleza eficiente y directa, **no requiere un alto poder de cómputo**.
- Es fácil de **implementar, fácilmente interpretable y ampliamente utilizado** por analistas de datos y científicos.
- La regresión logística puede manejar tanto variables **numéricas** como **categorías**, lo que la hace adecuada para trabajar con una amplia variedad de tipos de datos.
- La regresión logística es relativamente **robusta ante la presencia de valores atípicos o datos ruidosos**, lo que la hace adecuada para conjuntos de datos reales que pueden contener errores o valores extremos.

- No puede manejar una **gran cantidad** de características/variables categóricas
- Es **vulnerable** al sobreajuste.
- **No funcionará** bien con variables independientes que no estén correlacionadas con la variable de destino y que sean muy similares o estén correlacionadas entre sí.
- La regresión logística todavía puede **ser sensible a valores atípicos**, especialmente si estos tienen una influencia desproporcionada en el ajuste del modelo.

Desventajas



05

Lecturas complementarias

- Navlani, A. (2019). Understanding logistic Regression in Python Tutorial. <https://www.datacamp.com/tutorial/understanding-logistic-regression-python>
- Swaminathan, S. (2019, 18 enero). Logistic regression — detailed overview – towards data science. Medium. <https://towardsdatascience.com/logistic-regression-detailed-overview-46c4da4303bc>
- ¿Qué es la regresión logística? – Explicación del modelo de regresión Logística – AWS. (s. f.). Amazon Web Services, Inc. <https://aws.amazon.com/es/what-is/logistic-regression/>
- What is logistic regression? | IBM. (s. f.). <https://www.ibm.com/topics/logistic-regression>
- Logistic Regression: equation, assumptions, types, and best practices. (2022, 18 abril). Spiceworks. <https://www.spiceworks.com/tech/artificial-intelligence/articles/what-is-logistic-regression/>

