



A OTRO
NIVEL

VIRTUAL

REGULARIZACIÓN: RIDGE, LASSO Y ELASTIC NET

UNIDAD 1: APRENDIZAJE SUPERVISADO



Agenda

01

Acercamiento intuitivo

Sesgo
Varianza

02

Descripción matemática

Norma P
Regularización L1 y L2

03

Aplicación Real

Dataset para predecir las ventas

04

Consideraciones finales

Lambda
Lasso y Ridge

05

Lecturas complementarias


01

Acercamiento intuitivo



¿Que aprenderemos hoy?

- Importancia de calcular el error
- Efectos del sesgo (Bias)
- Efectos de la varianza (Variance)
- Balance Bias-Variance

Importancia de medir el error




Un **Error** puede ser descrito como una acción donde el resultado no corresponde a lo que se esperaba



Importancia de medir el error

- En ML el error se usa para observar la exactitud con la que un modelo realiza predicciones
- Es útil a la hora de seleccionar modelos



Tipos de error en ML

En ML hay dos tipos de error

Errores
irreducibles

Errores
reducibles




Regularización

La regularización es un conjunto de métodos para reducir el sobreajuste en modelos de Machine Learning.

Aumenta la generalización del modelo, mejorando su capacidad para predecir en datos nuevos.

Esto se logra a costa de una ligera disminución en la precisión del entrenamiento




Regularización vs. Optimización

- **Regularización:** Aumenta la capacidad de generalización del modelo.
- **Optimización:** Aumenta la precisión del modelo en los datos de entrenamiento.
- Ambos conceptos son fundamentales en Machine Learning.

- **Sobreajuste:** Ocurre cuando el modelo aprende demasiado bien los datos de entrenamiento, pero no generaliza bien a nuevos datos.
- **Subajuste:** Ocurre cuando el modelo no aprende lo suficiente, fallando tanto en entrenamiento como en pruebas.

La regularización ayuda a encontrar un equilibrio.

Sesgo y Varianza



A medida que agregamos más y más **parámetros** a nuestro modelo, su complejidad aumenta, lo que da como resultado una varianza creciente y un sesgo decreciente, es decir, **sobreajuste**.

Entonces, necesitamos encontrar un punto óptimo en nuestro modelo donde la **disminución del sesgo** sea igual al aumento de la **varianza**.

- **Sesgo alto** → Modelo demasiado simple, predicciones inexactas en entrenamiento.
- **Varianza alta** → Modelo demasiado complejo, predicciones inexactas en datos nuevos.
- **Compensación Sesgo-Varianza:** La regularización disminuye la varianza a costa de un mayor sesgo.

Balance entre sesgo y varianza

Bias


Variance

Bias

Variance

Bias

Variance



Diferencia entre los valores de **predicción** realizados por el modelo y los valores **reales/esperados**.




Fig. 3.a: Modelo demasiado simple




Fig. 3.b: Modelo de complejidad adecuada




Fig. 3.c: Modelo con demasiada complejidad

Si la diferencia entre estas dos magnitudes es **elevada**, estamos ante un modelo demasiado **simple** que no ha aprendido las relaciones relevantes entre las variables disponibles y la variable a predecir.

Regresión


Sub aprendizaje
(Alto Sesgo y Baja Varianza)
(underfitting)






Ajuste óptimo



Sobre aprendizaje
(Bajo Sesgo y Alta Varianza)
(overfitting)



Clasificación



**Evaluación en datos de
entrenamiento**

Pobre.

Buena.

Muy buena.

**Evaluación en datos de
validación y prueba**

Pobre.

Buena.

Pobre.

Métodos para combatir el sobre aprendizaje

Se pueden adoptar varios métodos para combatir el sobre aprendizaje:

- Validación cruzada (cross-validation)
- Reducción del número de atributos.
- Reducción de la complejidad del modelo.
- Regularización.

La regularización no se limita a los modelos lineales.

Se aplica en redes neuronales, árboles de decisión, SVM y otros modelos de Machine Learning.

En esta sección, nos enfocaremos en la **regularización en modelos lineales**.

Existen tres técnicas principales de regularización en regresión:

1.Regresión Lasso (L1)

2.Regresión Ridge (L2)

3.Red Elástica (Elastic Net)

¿Qué es una Norma L_n ?

En Machine Learning, la **norma** mide la magnitud de un vector en el espacio.

$$||w||_n = \left(\sum_{i=1}^d |w_i|^n \right)^{\frac{1}{n}}$$

- Norma L_1 : $||w||_1 = \sum |w_i| \rightarrow$ Suma de los valores absolutos.
- Norma L_2 : $||w||_2 = \sqrt{\sum w_i^2} \rightarrow$ Longitud euclidiana.

Regresión Lasso (L1)

(Least Absolute Shrinkage and Selection Operator)

- Penaliza los coeficientes grandes reduciéndolos a **cero**.
- Introduce un término de penalización basado en el **valor absoluto** de los coeficientes.
- Permite **selección de características**, eliminando predictores irrelevantes.
- Controlada por el hiperparámetro **lambda** (λ).

Usos:

- ✓ Cuando se busca reducir el número de predictores en el modelo.
- ✓ Ideal para datos con muchas variables irrelevantes.

Regularización L1 (Lasso)

$$\min_{\theta} \left(\sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^d |\theta_j| \right)$$

Regresión Ridge (L2)

- Penaliza los coeficientes grandes pero **no los reduce a cero**.
- Utiliza el **cuadrado de los coeficientes** en la función de pérdida.
- Reduce el impacto de características irrelevantes sin eliminarlas.

Diferencia clave con Lasso:

✗ No elimina características, solo disminuye su peso.

Usos:

- ✓ Cuando todas las características aportan información relevante.
- ✓ Útil en problemas con **colinealidad** (cuando las variables están correlacionadas).

Regularización L2 (Ridge)

$$\min_{\theta} \left(\sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^d \theta_j^2 \right)$$

Regularización de Red Elástica (Elastic Net)

- **Combinación de Lasso y Ridge.**
- Usa **L1 y L2** en la función de pérdida.
- Permite la selección de características (**como Lasso**).
- Reduce el impacto de características irrelevantes (**como Ridge**).

Usos:


- ✓ Cuando hay muchas variables correlacionadas.
- ✓ Cuando se desea selección de características pero con cierta suavidad.

Regularización Elastic Net

$$\min_{\theta} \left(\sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda_1 \sum_{j=1}^d |\theta_j| + \lambda_2 \sum_{j=1}^d \theta_j^2 \right)$$


Regularización

Modifica la función de costo de forma tal que además de **penalizar los errores** de predicción, se **penalicen magnitudes grandes** de los coeficientes W_j (para $j \neq 0$) que caracterizan al modelo.




Regularización


Ridge



Lasso



Elastic Net



02

Acercamiento intuitivo

Sesgo

Varianza

03

Descripción matemática

Norma P

Regularización L1 y L2

04

Consideraciones finales

Lambda

Lasso y Ridge

Lambda (λ)

Este parámetro sirve para controlar el **impacto relativo** de los dos términos en la función de costo.

- Cuando $\lambda = 0$, la penalidad no tiene efecto.
- Entre más grande λ , los coeficientes estimados van a ser más pequeños.
- Se puede usar **validación cruzada** para optimizar este hiperparámetro.
- Al introducir el término de regularización en la función de costo, se cambia la expresión para el gradiente, y por ende se debe actualizar el código que encuentra los coeficientes usando el gradiente descendente.

Lasso (L1)

Cost function = Loss + $\lambda \times \sum \|w\|$

Here,

Loss = Sum of the squared residuals

λ = Penalty for the errors

w = slope of the curve/ line




Figure 13: Lasso Regression

Least Absolute Shrinkage and Selection Operator (Lasso) agrega un término de penalización (l1) a la función de costo.


Este término es la suma absoluta de los coeficientes.

- Sirve como **método de selección de atributos**, en caso de correlación de las variables independientes:
 - Escoge arbitrariamente cualquiera de las variables altamente correlacionadas.
 - Puede haber problemas en caso de términos polinomiales que puedan desaparecer al estar correlacionados entre ellos.
- Produce modelos más simples, robustos con respecto al sobre entrenamiento, y fáciles de interpretar.
- Produce modelos “poco densos” (**sparse**).

Ridge (L2)

Penaliza la suma de los coeficientes elevados al cuadrado.

A esta penalización se le conoce como **L2** y tiene el efecto de reducir de forma proporcional el valor de todos los coeficientes del modelo pero sin que estos lleguen a cero.



$$\text{Cost function} = \text{Loss} + \lambda \times \sum \|w\|^2$$

Here,


Loss = Sum of the squared residuals

λ = Penalty for the errors


W = slope of the curve/ line

- Todos los atributos predictores están presentes en el modelo.
- El modelo resultante es **difícil de interpretar** si hay muchas variables predictivas.
- En caso de correlación de las variables independientes funciona bien.
- Se usa para prevenir el sobre entrenamiento (**overfitting**).


1.




2.




3.




4.




5.



6.



7.




$$\text{Tamaño} = 1.5 + 0.7 * \text{Alta grasa}$$

$$\text{Least square Error} + \lambda * \text{Diferencia medias}^2$$

Si λ es grande
Se disminuye la diferencia
Entre las means


8.




9.



10.



11.



05

Lecturas complementarias

Ridge


https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Ridge.html#sklearn.linear_model.Ridge

Lasso

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Lasso.html

Elastic Net

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.ElasticNet.html#sklearn.linear_model.ElasticNet



07

Preguntas de revisión



¿Cuáles son algunos métodos para combatir el sobre aprendizaje?

☐ Aumentar las iteraciones en los algoritmos y utilizar modelos más complejos.

☐ Validación cruzada y regularización.

☐ Recolectar más datos



¿Cuáles son algunos métodos para combatir el sobre aprendizaje?

☐ Aumentar las iteraciones en los algoritmos y utilizar modelos más complejos.

☒ Validación cruzada y regularización.

☐ Recolectar más datos



¿Qué es el sesgo?

☐ Que se presta mucha atención a las características de los datos empleados.

☐ Sensibilidad a diferentes conjuntos de datos.

☐ Diferencia entre los valores predichos por el modelo y los reales.



¿Qué es el sesgo?

☐ Que se presta mucha atención a las características de los datos empleados.

☐ Sensibilidad a diferentes conjuntos de datos.

☒ Diferencia entre los valores predichos por el modelo y los reales.



¿Qué significa que el valor de la varianza sea alto?


- ☐ Modelo es demasiado complejo y presta atención en exceso a las características del subconjunto empleado frente a los patrones generales.
- ☐ Se presenta underfitting en el modelo.
- ☐ Es un modelo demasiado simple.




¿Qué significa que el valor de la varianza sea alto?



Modelo es demasiado complejo y presta atención en exceso a las características del subconjunto empleado frente a los patrones generales.



Se presenta underfitting en el modelo.



Es un modelo demasiado simple.



¿Cuáles son las técnicas de regularización?

☐ Ridge, Lasso y regresión multivariada.

☐ Lasso y Knn.

☐ Lasso, Ridge y Elastic Net.



¿Cuáles son las técnicas de regularización?

☐ Ridge, Lasso y regresión multivariada.

☐ Lasso y Knn.

☒ Lasso, Ridge y Elastic Net.



¿Cuál es la principal diferencia entre Lasso y Ridge?


- ☐ Ridge reduce los coeficientes pero sin que estos lleguen a 0, mientras que Lasso puede reducirlos a 0.
- ☐ Lasso reduce los coeficientes pero sin que estos lleguen a 0, mientras que Ridge puede reducirlos a 0.
- ☐ Ridge es un método de selección de atributos mientras que Lasso no.




¿Cuál es la principal diferencia entre Lasso y Ridge?



Ridge reduce los coeficientes pero sin que estos lleguen a 0, mientras que Lasso puede reducirlos a 0.



Lasso reduce los coeficientes pero sin que estos lleguen a 0, mientras que Ridge puede reducirlos a 0.



Ridge es un método de selección de atributos mientras que Lasso no.