

¿Qué es la regularización?

Machine learning

Le damos la bienvenida

- ▶ Introducción
- ▶ Ciencia de datos para machine learning
- ▶ Ingeniería de características
- ▶ Aprendizaje supervisado
- ▶ Aprendizaje no supervisado
- ▶ Aprendizaje semisupervisado
- ▶ Aprendizaje de refuerzo
- ▶ Deep learning
- ▶ Generative AI
- ▼ Entrenamiento de modelos
 - Visión general
 - Función de pérdida
 - Datos de entrenamiento
 - Parámetros del modelo
 - ▶ Algoritmo de optimización
 - ▶ Hiperparámetros del modelo
 - ▶ Ajuste preciso

Regularización

Modelos fundacionales

Sobreaajuste

Infraajuste

► Aprendizaje n-shot

Destilación de conocimientos

Autores



Jacob Murel Ph.D.

Senior Technical Content
Creator

¿Qué es la regularización?

La regularización es un conjunto de técnicas utilizadas en los modelos de machine learning que busca compensar una disminución marginal en el rendimiento con un aumento en la generalización.

La regularización abarca una serie de técnicas de [machine learning](#). Como tal, la regularización busca mejorar la generalización de un modelo, es decir, su capacidad para desempeñarse en nuevos [conjuntos de datos](#)¹. La regularización busca mejorar la generalizabilidad a costa de un mayor error de entrenamiento. Los métodos de regularización suelen dar lugar a [datos de entrenamiento](#), pero a predicciones más precisas.

La regularización se diferencia de la optimización en que busca mejorar la generalizabilidad del modelo, mientras que la optimización busca mejorar el rendimiento de entrenamiento del modelo. Ambos son conceptos relacionados con el aprendizaje de datos.

Existen muchas formas de regularización. Cada una completa requiere un tratamiento mucho más detallado. Esta sección proporciona una descripción general de la técnica de la regularización en el machine learning, a través de algunas de las regularizaciones populares.

Equilibrio entre sesgo y varianza

Esta concesión de un mayor error de entrenamiento a cambio de un menor error de prueba se conoce como compensación de sesgo-varianza. Este es un problema muy conocido en el machine learning, a menudo referido como "sesgo" y "varianza". En pocas palabras:

- El **sesgo** mide la diferencia media entre lo que el modelo predice y la medida que aumenta el sesgo, un modelo con alto sesgo se ajusta demasiado a los datos de entrenamiento. Un sesgo alto en un modelo de datos de entrenamiento.
- La **varianza** mide la diferencia entre las predicciones de un modelo determinado. A medida que aumenta la varianza, la precisión sobre datos no vistos. Un modelo con alta varianza tiene un error durante las pruebas y la validación.

El sesgo y la varianza representan inversamente la relación entre el error de entrenamiento y prueba, respectivamente. Pretenden reducir tanto el sesgo como la varianza, pero en ambos no siempre es posible, lo que resulta en un equilibrio. La regularización disminuye la varianza del modelo.

Ajustes del modelo de regresión

Al aumentar el sesgo y disminuir la varianza, se produce el sobreajuste. El sobreajuste se produce cuando el modelo se ajusta demasiado a los datos de entrenamiento, lo que resulta en un error en los datos de prueba que aumenta. En otras palabras, el sobreajuste ocurre cuando el modelo tiene una alta varianza. No obstante, si la regularización está bien ajustada, el modelo ajustará bien.

A pesar de su nombre, el **infraajuste** no denota un modelo que se ajusta demasiado a los datos de entrenamiento, describe modelos caracterizados por un alto sesgo y una baja varianza.

ajustado produce predicciones insatisfactorias en las pruebas. Esto suele deberse a datos o [parámetros](#)

Sin embargo, la regularización también puede afectar al rendimiento del modelo. Si se introduce demasiado sesgo, el modelo puede dejar de disminuir e incluso aumentar el error. Este efecto sobre todo en modelos simples, es del tipo y el grado de regularización que se va a introducir. En la complejidad del modelo, el conjunto de datos

Boletín del sector

Las últimas tendencias por expertos

Obtenga conocimientos organizados sobre las últimas tendencias intrigantes de la IA. Suscríbase a nuestro boletín. [Declaración de privacidad de IBM.](#)

johndoe@yourdomain.com

Tipos de regularización lineales

La [regresión lineal](#) y la [regresión logística](#) son técnicas de machine learning. El objetivo de la regresión lineal es medir y predecir el impacto de uno o varios predictores encontrando la línea que mejor se ajuste a través de los datos (es decir, los datos de entrenamiento). La regresión logística calcula las probabilidades de clase de mediante una salida



otras palabras, la regresión lineal realiza predicciones más precisas que la regresión logística produce predicciones.

Por supuesto, a medida que aumenta el número de modelos de regresión, la relación insumo-producto cambia. Manipular la fórmula de regresión. Introduzca los principales de regularización para los modelos de regresión. Esta lista es solo un breve repaso. La aplicación de regularización a la regresión lineal o logística varía minuciosamente.

- **- La regresión de Lasso** (o regularización L1) penaliza los coeficientes correlacionados. La regularización (también llamado término de penalización) se suma a la suma de errores cuadrados (SSE) del modelo. El término de penalización es la suma absoluta de la suma de coeficientes. Controlando el parámetro lambda (λ), reduce a cero las ponderaciones de los coeficientes. La regresión de Lasso elimina por completo los coeficientes de los modelos.
- **La regresión de Ridge** (o regularización L2) penaliza de manera similar los coeficientes. La penalización en la función de pérdida SSE de Lasso. En primer lugar, el término de penalización es el cuadrado de los coeficientes en lugar de la suma absoluta. En segundo lugar, la regresión de Ridge no penaliza los coeficientes a cero. Mientras que el término de penalización de Lasso reduce a cero los coeficientes de las características del modelo reduciendo los pesos de los coeficientes, la regresión de Ridge solo reduce los pesos de los coeficientes.
- **- La regularización de red elástica** combina la regularización de Lasso, pero inserta los términos de penalización L2 y L1. Los términos de penalización L2 y L1 derivan su valor del término de penalización de L2 o tomando el valor absoluto de los coeficientes. La red elástica inserta ambos valores de penalización en la función de costo (SSE). De este modo, la red elástica permite la selección de características⁶.

En estadística, estos métodos también se denominan métodos de reducción de los valores de los coeficientes predictivos.

técnicas, la fuerza del término de penalización
calcular utilizando varias técnicas de validación

Mixture of Experts | 28 de agosto, episodio



Descifrar la IA: resumen sem

Únase a nuestro panel de ingenieros
producto y otros profesionales de ta
el bullicio de la IA para ofrecerle las
respeto.


[Ver los últimos episodios del podcast](#) —

Tipos de regularización learning

Conjunto de datos

El aumento de datos es una técnica de regulación
entrenamiento del modelo. Amplía el tamaño
muestras de datos artificiales derivadas de di
más muestras al conjunto de entrenamiento,
datos del mundo real, expone un modelo a un

los que aprender. La investigación en machine learning muestra un aumento de datos para clasificadores, en particular para datos desequilibrados.⁷ Sin embargo, el aumento de datos produce duplicados modificados de datos preexistentes. El segundo implica la creación de nuevos datos sintéticos que produce duplicados modificados de datos preexistentes en el conjunto de datos.




Entrenamiento de modelo

La detención temprana es quizás la técnica más comúnmente aplicada. En resumen, limita el número de iteraciones de entrenamiento. En este caso, un modelo pasa continuamente

deteniéndose una vez que no hay mejora (y que el error de validación comienza a aumentar). El objetivo es encontrar el menor error de entrenamiento posible antes de que el error de validación comience a aumentar.

Muchos paquetes Python de machine learning implementan la detención temprana. En este caso, es el entorno de entrenamiento por defecto.




Early stopping

Neural networks

Las **redes neuronales** son modelos complejos: aplicaciones y servicios de **inteligencia artificial** que tienen una capa de entrada, una o más capas ocultas y una capa de salida compuesta por varios nodos.

El abandono regulariza las redes neuronales al eliminar algunas de sus conexiones de entrada y salida, de las redes ocultas (Fig. 3). El abandono entrena varias variaciones de la red, cada variación con diferentes nodos aleatoriamente eliminados. En las pruebas se utiliza una única red neuronal sin dropout, cuyo promedio aproximado derivado de las arquitecturas de las variaciones aleatorias. De esta manera, el abandono regulariza la cantidad de redes neuronales con una multitud de variaciones.





La **caída del peso** es otra forma de regularizar redes neuronales profundas. Reduce la suma de los pesos cuadráticos de la red, al igual que la regularización L2. En la regularización L1, el peso de las neuronas seleccionadas disminuye a cero, reduciendo la complejidad de la red.

La pérdida de peso puede parecer superficial en redes neuronales profundas, pero las dos técnicas tienen una diferencia clave: en el abandono, el valor de los pesos se reduce a cero, mientras que en la caída del peso, los pesos se reducen gradualmente.

peso aumenta de forma lineal. Algunos creen de manera más significativa la complejidad d

Muchos artículos y tutoriales en línea confun y la caída del peso. De hecho, la beca es incol caída del peso,¹⁴, otros la equiparan,¹⁵, mientr la relación entre ellos.¹⁶ Resolver esas incohe necesaria pero pasada por alto para futuras b

Libro electrónico

Desbloquee el poder de la IA generativa + ML

Aprenda a incorporar con confianza la IA generativa y el machine learning a su negocio.

[Lea el e-book](#)



Notas a pie de página

[1] [Deep Learning](#). Goodfellow et al. The MIT Press. 2016

[2] *An Introduction to Statistical Learning*. G. James et al.

[3] [Deep Learning](#). Goodfellow et al.

[4] Vandenbussche, Vincent. [Regularization cookbook](#). Pa

[5] *An Introduction to Statistical Learning*. G. James et al.

[6] *Applied Predictive Modeling*. Kuhn, Max y Johnson, Kj
Methods and Applications. Fahrmeir, Ludwig, et al. 2.^a ed

[7] [“Simple Copy-Paste Is a Strong Data Augmentation M](#)
2021.

[8] *Neural Networks: Tricks of the Trade*. Montavon. et al.

[9] [“Dropout: A Simple Way to Prevent Neural Networks f](#)

[10] *Applied Predictive Modeling*. Kuhn, Max y Johnson, K

[11] [“Deep Learning Meets Sparse Regularization: A Sign](#)

[12] [“Comparing Biases for Minimal Network Constructio](#)
1988.

[13] [“Surprising properties of dropout in deep networks”](#). Helmbold, David y Long, Philip. JMLR. 2018.

[14] [“Three Mechanisms of Weight Decay Regularization”](#). Zhang, Guodong, Wang, Chaoqi, Xu, Bowen, Roger,
Grosse. arXiv. 2018.

[15] [“Fundamental differences between Dropout and Weight Decay in Deep Networks”](#). Helmbold, David y Long,
Philip. ResearchGate. 2016.

[16] [Deep Learning](#). Goodfellow et al.

Recursos

Formación

Amplíe sus conocimientos de
ML

Aprenda los conceptos fundamentales y desarrolle sus habilidades con laboratorios prácticos, cursos, proyectos guiados, pruebas y mucho más.

[Explore cursos de ML](#)



Libro electrónico

Desbloquee el poder de la IA generativa + ML

Aprenda a incorporar con confianza la IA generativa y el machine learning a su negocio.

[Lea el e-book](#)



Guía

Ponga la IA a trabajar: cómo impulsar el ROI con la IA generativa

¿Quiere obtener un mayor rendimiento de sus inversiones en IA? Descubra cómo escalar la IA generativa en áreas clave impulsa el cambio ayudando a sus mentes más brillantes a crear y ofrecer nuevas soluciones innovadoras.

[Lea la guía](#)



Libro electrónico

Cómo elegir el modelo fundacional adecuado

Aprenda a seleccionar el modelo fundacional de IA más adecuado para su caso de uso.

[Lea el e-book](#)



Modelos de IA

Explore IBM Granite

IBM Granite es nuestra familia de modelos de IA abiertos, eficaces y de confianza, adaptados a la empresa y optimizados para escalar sus aplicaciones de IA. Explore las opciones de idioma, código, series de tiempo y salvaguardas.

[Conozca Granite](#)



Guía

Cómo prosperar en la era de la IA con seguridad y confianza

Profundice en los tres elementos cruciales de una estrategia de IA sólida: crear una ventaja competitiva, ampliar la IA en toda la empresa y promover una IA fiable.

[Lea la guía](#)



Informe

Informe AI in Action

Hemos encuestado a 2000 organizaciones sobre sus iniciativas de IA para descubrir qué funciona, qué no y cómo puede adelantarse.

[Lea el informe](#)



1 / 2




Soluciones relacionadas



IBM watsonx.ai

Entrene, valide, ajuste e implemente IA generativa, modelos fundacionales y capacidades de machine learning con IBM watsonx.ai, un estudio empresarial




Soluciones de inteligencia artificial

Ponga la IA a trabajar en su negocio con la experiencia líder en IA del sector de IBM y junto a su cartera de soluciones.

de nueva generación para desarrolladores de IA. Cree aplicaciones de IA en menos tiempo y con menos datos.

[Descubra watsonx.ai](#) →

[Explore las soluciones de IA](#) →



Consultoría y servicios de IA

Reinvente las operaciones y flujos de trabajo críticos añadiendo IA para maximizar las experiencias, la toma de decisiones en tiempo real y el valor empresarial.

[Explore los servicios de IA](#) →

Dé el siguiente paso

Obtenga acceso único a capacidades que abarcan el ciclo de vida de desarrollo de la IA. Produzca potentes soluciones de IA con interfaces intuitivas, flujos de trabajo y acceso a API y SDK estándar del sector.

[**Explore watsonx.ai**](#)[**Solicite una demostración en directo**](#)