



Aprendizaje automático I - 252

[Inicio](#)[Presentación](#)[Diapositivas y videos de clase](#)[Unidad 1](#)[Unidad 2](#)[Unidad 3](#)[otros](#)[Unidad 4](#)[Unidad 5](#)[Taller práctico](#)

Examen validación conocimien...

Unidad 4



Unidad 4: Métricas de evaluación



Sesión 9

Introducción: Métricas de Desempeño y Protocolos de Validación en Modelos de Machine Learning

En el desarrollo de modelos de *Machine Learning*, evaluar su desempeño de manera precisa es un paso fundamental. Más allá de la construcción de algoritmos, la capacidad para interpretar adecuadamente cómo funcionan y qué tan bien se comportan en diferentes escenarios es lo que permite tomar decisiones informadas y construir soluciones robustas y confiables.

Esta unidad se centra en el estudio detallado de **métricas de desempeño**, herramientas esenciales para medir la calidad de los modelos, tanto en tareas de **regresión** como de **clasificación**. Comprender cuándo y por qué utilizar una métrica específica es crucial, ya que cada una ofrece una perspectiva distinta sobre el comportamiento del modelo y puede llevar a interpretaciones diferentes si no se elige

con cuidado.

En **regresión**, se estudian métricas como el **Error Cuadrático Medio (MSE)**, el **Error Absoluto Medio (MAE)** y el **Coeficiente de Determinación (R^2)**, que cuantifican la diferencia entre las predicciones numéricas del modelo y los valores reales. En **clasificación**, el enfoque se centra en métricas como la **Precisión**, la **Exhaustividad (Recall)**, la **Puntuación F1** y la **Curva ROC-AUC**, que evalúan el desempeño del modelo al predecir categorías o clases.

Cada métrica posee **ventajas y limitaciones**: algunas son más sensibles a los errores grandes, otras equilibran el impacto de los falsos positivos y negativos, y otras pueden ser engañosas si no se interpretan dentro del contexto adecuado. Por ello, en esta unidad no solo se revisarán los fundamentos matemáticos de cada métrica, sino también los escenarios donde su uso es más o menos conveniente.

Finalmente, para asegurar que la evaluación sea representativa y generalizable, se abordarán los **protocolos de validación**, como la **validación cruzada (cross-validation)**. Este tipo de técnicas permiten estimar de manera más fiable el rendimiento de un modelo, evitando problemas como el *overfitting* o evaluaciones optimistas debido a datos de prueba mal distribuidos.



Base de datos y [notebooks](#)

En las siguientes carpetas encontrarás las bases de datos y los notebooks_ que usaremos durante las sesiones



Carpeta

Notebooks_S9



Carpeta

Data_S9



Antes de la Clase :

Los estudiantes deben hacer una lectura previa sobre métricas empleadas para evaluar el desempeño de modelos en machine learning.

Lectura previa: [medium performance metrics](#)

Lectura previa: [Clinical-Epidemiology: chapter 8](#)

Lectura previa: [A review of model evaluation metrics](#)

Lectura previa: [cross validation scikit-learn](#)

Lectura previa: [cross validation](#)



Recurso

[Clinical-Epidemiology: chapter 8](#)



Durante la Clase :

Cálculo e Interpretación de métricas:

Métricas de evaluación para regresión: RMSE, MAE, R^2 .

Métricas para clasificación: matriz de confusión, accuracy, precisión, recall, F1-score, curva ROC-AUC.

Validación cruzada: fundamentos y aplicación práctica.

Comparación de diferentes modelos de clasificación utilizando métricas de desempeño en un problema binario.



Recurso



Roc1



Recurso

Roc2



Sesión 10

Cuestionario para evaluar: Regularización Lasso y Ridge en Regresión y Clasificación y Métricas de Clasificación



Carpeta

Actividad_metricas



Cuestionario

Quiz 3



Cuestionario

Quiz 3 (sin aleatorizar)



Cuestionario

Quiz 3 (versión 2 - lunes 01 septiembre).